你的基准是难度上的一个经验测度

Yifan Sun[†*] **Naicheng Yu**[‡*] **Jiawen Gong**[†*] **Jingyan Shen**[§] **Huan Zhang**[†]

[†]University of Illinois Urbana-Champaign [‡]University of California San Diego
[§]New York University

项目网站： benchmark-difficulty-measure.github.io

GitHub 代码： https://github.com/ASTRAL-Group/benchmark-difficulty-measure

BenchFill 数据集： https://huggingface.co/datasets/Yifan99/BenchFill

摘要

基准并非仅仅是一组测试题目的集合；它自然地在难度上诱导出一个经验测度。本文建立这种基于测度的基准评测观点。这一视角使我们能够识别并形式化两种核心失效模式：*测度失配*，即基准的难度分布不同于预期的难度分布；以及*覆盖缺口*，即难度轴上未被覆盖的区域使基准无法检测有意义的局部训练进展。我们提出两个诊断指标来刻画这两种失效模式，并给出严格的理论保证。在实验上，我们利用仔细估计的题目难度，分析了涵盖 **7** 个领域的 **25** 个常用基准。结果表明，许多基准隐含地过度加权某些难度区域，因此其排行榜结论应谨慎解读；另一些基准则在难度轴上留下大段未覆盖区间，从而限制了它们监测模型改进过程的能力。最后，我们将诊断转化为行动，提出 BenchFill，一种面向目标难度的简单题目改写算法，能够有效缩小局部覆盖缺口。

1 引言

基准评测看起来很简单：我们在一组题目上运行模型并取平均。所得分数主要有两种用途：在排行榜上比较模型 [2, 64, 29, 45]，以及在训练过程中监测进展 [33, 21, 16, 6, 38]。但这种简单性掩盖了一个基本问题：结论不仅取决于模型表现如何，也取决于基准题目如何分布 [59, 73]。

首先考虑图 1(a) 中的排行榜设定，我们希望比较两个模型。假设它们在简单题上表现相近，但在难题上差异很大。若基准把大部分权重放在简单题上，而我们关心的难度分布把更多权重放在更难的题目上，则同对模型的两次评测可能得出不同结论：基准可能表明两个模型几乎打平，但在期望的难度分布下它们明显分开。再考虑图 1(b) 中的训练设定，我们希望追踪模型是否在改进。假设模型在某个局部难度区间上有*显著*提升。若基准在该区域几乎没有或完全没有题目，基准分数可能几乎不变，尽管模型已经取得了真实进展。

这两个失效情形表明，基准结论关键取决于题目如何分布。为系统地研究这一结构，我们把基准题目排列在一条**难度**轴上，它提供了从较易到较难问题的自然递进。关键的概念步骤是用难度来定义基准自身的分布结构。这一观点将基准从一组测试题目，重构为难度上的一个**经验测度**，每道题在其难度水平上贡献相等的评测质量。

这种测度论形式化之所以有用，是因为它把上述两种失效情形转化为关于基准所诱导难度测度的精确、可分析问题。第一个是**测度失配**问题：基准分配质量的方式可能不同于代表预期评测目标的目标难度分布，因此基准结论可以不同于目标难度分布下的结论。第二个是**覆盖缺口**问题。由于基准是仅支撑在有限个难度点上的经验测度，可能存在几乎没有或完全没有基准质量的难度区间。集中在这样一个区间内的显著性能增益，因此可能几乎不改变、甚至完全不改变基准分数。据我们所知，这是首次将测度失配与覆盖缺口识别并形式化为基准评测的两种基本失效模式的工作。

*同等贡献。
通讯作者：Yifan Sun <yifan50@illinois.edu> 与 Huan Zhang <huan@huan-zhang.com>。

40th Conference on Neural Information Processing Systems (NeurIPS 2026). Track on Evaluations and Datasets.

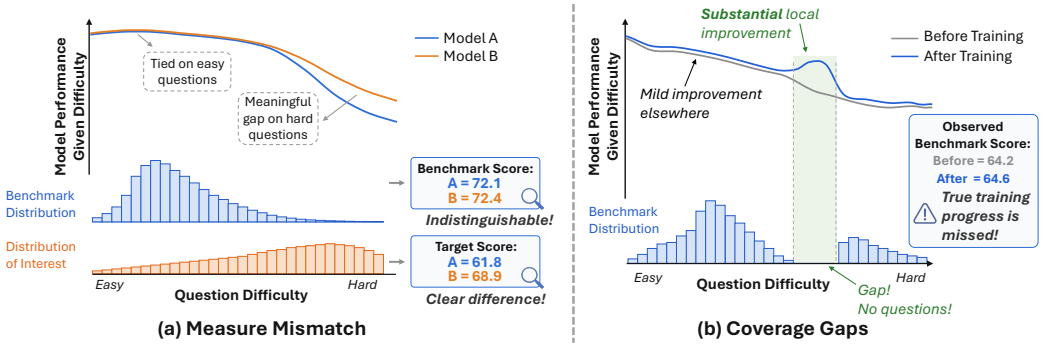

图 1: **两种基准失效情形。**两幅图中的曲线均表示真实模型的*条件*性能，即*作为题目难度的函数*。(a) **测度失配。**基准强调简单题，而模型在简单题上表现相近；我们关心的难度分布则把更多权重放在更难的题目上，模型在这些题目上差异很大。由于基准与目标分布对难度轴的加权不同，它们对同一对模型给出不同结论。(b) **覆盖缺口。**模型实际上在某个局部难度区域上有*显著*提升。由于基准在该区域没有题目，这一提升没有反映在观测到的基准分数中，导致有意义的训练进展被遗漏。

这两个问题自然引出两个简单的诊断指标：基准测度与目标难度分布之间的 Wasserstein 距离 [63]，以及相邻基准难度点之间的最大间隔。我们给出理论结果，表明这些量直接刻画分布失配以及局部改进的可检测性。在实验上，我们分析了涵盖 **7** 个领域的 **25** 个常用基准。我们用项目反应理论（Item Response Theory, IRT）估计题目难度并计算所提出的指标。结果表明，这两个问题在各类基准中普遍存在。

我们的主要贡献概括如下：

- 我们提出一种基于测度的基准评测新视角，将基准表示为难度上的经验测度。该视角形式化了测度失配与覆盖缺口，引出两个诊断指标，并给出严格的理论保证。
- 我们在涵盖 **7** 个领域的 **25** 个基准上开展实证研究，表明难度分布失配与大覆盖缺口在当前基准中广泛存在。
- 我们提出 BenchFill，一种面向目标难度的缺口填补算法。每个基准仅插入三道题，BenchFill 就将前三大难度间隔之和降低 21.09%–38.88%。

2 形式化与理论

难度空间与模型性能函数。 我们用连续变量 $z \in [0,1]$ 表示基准题目（例如一道题）的难度，较大的值对应较难的题目。对模型 θ，令 $s_\theta(z) \in [0,1]$ 表示其在难度为 z 的题目上的条件期望性能，例如 pass@1。

基准分布与分数。 设基准 $B = \{x_i\}_{i=1}^n$ 由 n 道题组成，并令 $z_i \in [0,1]$ 表示题目 x_i 的难度。基准分数为 $S_B(\theta) := \frac{1}{n}\sum_{i=1}^n s_\theta(z_i)$。这一平均隐式地在难度轴上诱导出一个经验测度，

$$\nu_B = \frac{1}{n}\sum_{i=1}^{n} \delta_{z_i},$$

其中 δ_z 表示位于难度 z 处的点质量。在这一表示下，基准分数恰好是关于基准所诱导难度测度的积分，$S_B(\theta) = \int s_\theta(z)\, d\nu_B(z)$。

两个模型之间的性能差。 对两个模型 θ 与 θ'，定义*难度条件下的性能差*为 $\Delta(z) := s_{\theta'}(z) - s_\theta(z)$，为记号简便，省略 Δ 对 (θ', θ) 的依赖。*在基准 B 上观测到的*性能差为

$$D_B(\theta', \theta) := S_B(\theta') - S_B(\theta) = \frac{1}{n}\sum_{i=1}^{n} \Delta(z_i) = \int \Delta(z)\, d\nu_B(z).$$

2.1 测度失配

基准诱导的耦合。 量 $D_B(\theta', \theta)$ 隐式地耦合了两个不同对象：*依赖模型的函数* $\Delta(z)$ *与依赖基准的测度* ν_B。因此，排行榜比较并非仅由模型之间难度条件下的性能差决定；它还取决于基准

如何在难度轴上分配质量。若这一分配不同于我们关心的难度分布，基准就会在失配的测度下聚合同一模型差异。这种失配可能扭曲观测到的模型差距，在严重情形下还会改变所诱导的排序。

目标分布。 形式上，我们引入目标分布 $\mu \in \mathcal{P}([0,1])$, 它表示难度空间上预期的评测分布。该目标分布可以编码期望的应用组合。在 μ 下，模型 θ 的目标分数以及 θ' 与 θ 之间的目标性能差定义为

$$S_\mu(\theta) := \int s_\theta(z)\, d\mu(z), \qquad D_\mu(\theta', \theta) := S_\mu(\theta') - S_\mu(\theta) = \int \Delta(z)\, d\mu(z).$$

$D_B(\theta', \theta)$ 与 $D_\mu(\theta', \theta)$ 之间的差异来自基准测度 ν_B 与目标分布 μ 的失配。这一观点使我们可以把排行榜比较中的扭曲作为分布失配问题来研究。

分布失配的度量。 我们用 1-Wasserstein 距离衡量基准的难度分布与目标难度分布的匹配程度。具体地，对经验难度测度为 ν_B 的基准 B 以及 $[0,1]$ 上的目标分布 μ，我们将其*难度分布失配（Difficulty Distribution Mismatch, DDM）*定义为

$$\mathrm{DDM}(B; \mu) := W_1(\nu_B, \mu) = \inf_{\pi \in \Pi(\nu_B, \mu)} \int_{[0,1]^2} |u - v|\, d\pi(u, v),$$

其中 $\Pi(\nu_B, \mu)$ 表示 ν_B 与 μ 的所有耦合构成的集合。直观上，$W_1(\nu_B, \mu)$ 衡量要把基准难度分布变换成目标分布，需要搬运多少概率质量、以及搬运多远。下面的定理表明，这种失配直接控制基于基准与基于目标的性能差之间的扭曲。

定理 2.1 (分布失配控制分数扭曲与排名稳定性)**.** *设性能差函数 Δ 是 L-Lipschitz 的。则*

$$\big|D_B(\theta', \theta) - D_\mu(\theta', \theta)\big| \le L\, W_1(\nu_B, \mu).$$

因此，若 $|D_\mu(\theta', \theta)| > L\, W_1(\nu_B, \mu)$，则

$$\mathrm{sign}\big(D_B(\theta', \theta)\big) = \mathrm{sign}\big(D_\mu(\theta', \theta)\big),$$

从而基准所诱导的排序与目标排序一致，即不会发生排名翻转。

定理 2.1 表明，$W_1(\nu_B, \mu)$ 界定了基准所诱导的分数差与目标分数差之间可以相差多少。较小的 $W_1(\nu_B, \mu)$ 意味着基准是目标评测的忠实近似，而较大的 $W_1(\nu_B, \mu)$ 表明基准可能过度强调某些难度区域、同时低估另一些区域，从而可能扭曲模型比较，甚至改变其诱导排名。附录 B.1 给出完整证明，并将该结果推广到有限样本设定。

无先验信息时有原则的目标分布。 当已有先验信息时，自然应选择 μ 以反映难度空间上预期的评测目标。然而在许多设定中，此类先验知识不可得。此时，选择非均匀目标会在没有证据的情况下隐含地偏袒某些难度区域。为刻画一个有原则的默认选择，我们考虑一种不可知设定：性能差沿难度轴出现的位置完全未知。我们考虑函数类

$$\mathcal{F}_\rho := \left\{ \Delta : [0,1] \to [-1,1] \text{ 可测} : \int_0^1 \Delta(z)\, dz = \rho \right\}, \qquad \rho \in (-1, 1).$$

该类编码一个不确定性集合：带符号的性能差在难度轴上具有固定的平均水平 ρ，但其位置除此之外不受限制。

对任意候选目标分布 $\mu \in \mathcal{P}([0,1])$，定义其最坏情形保留差为

$$V_\rho(\mu) := \inf_{\Delta \in \mathcal{F}_\rho} \int \Delta(z)\, d\mu(z).$$

下面的定理表明，当对性能差沿难度轴出现的位置完全不确定时，均匀分布是*唯*一的极大极小（maximin）目标，并且是唯一使最坏情形保留差仍等于平均差 ρ 的选择。

定理 2.2 (均匀目标是唯一的极大极小选择)**.** *对 $\rho \in (-1, 1)$，我们有*

$$\sup_{\mu \in \mathcal{P}([0,1])} V_\rho(\mu) = \rho,$$

且唯一的最大化子是均匀分布 $\lambda = \mathrm{Unif}[0,1]$。

定理 2.2 并不声称均匀分布在一切情形下都最优。它只是在难度空间上没有先验信息时，为把均匀分布作为有原则的默认目标提供依据。此时，采用均匀目标避免了对难度区域引入额外偏好，并为基准评测提供一条中性准则：评测并不先验地偏袒任何难度区域。完整证明见附录 B.1。

2.2 覆盖缺口

离散的基准测度可能无法监测局部训练改进。 基准不仅常用于最终的模型比较，也用于监测训练进展 [16, 69, 38]。然而，训练改进往往是局部的而非均匀的：模型可能在某一特定难度范围内大幅提升，而在其他地方仅有适度改进。

回想基准分数是关于基准经验测度 ν_B 的积分。由于 ν_B 是*离散*测度，仅支撑在有限个基准难度点上，它对每一个不含基准题目的区间都赋予零质量。因此，即使模型在一段非平凡的连续难度区域上有显著改进，只要该区域不含基准题目，基准分数也可能反映不出这一改进。在这个意义上，当局部分辨率不足时，基准作为进展监测器会失效。

最大间隔。 我们首先用*最大间隔*刻画基准的局部分辨率。令 $0 \le z_{(1)} \le \cdots \le z_{(n)} \le 1$ 为有序的基准难度点，并定义 $z_{(0)} := 0$ 与 $z_{(n+1)} := 1$。基准 B 的*最大间隔*为

$$G(B) := \max_{0 \le j \le n} \big(z_{(j+1)} - z_{(j)}\big) \tag{1}$$

即难度轴上不含任何基准点的最大区间的长度。

假设检验表述。 为形式化基准能否可靠检测局部训练改进，我们将该问题表述为假设检验。在原假设下没有改进。在备择假设下，改进后的性能在某个宽度为 w 的连续难度区间上，至少比改进前高出 a。下面的定理表明，基准最大间隔 $G(B)$ 正是精确的渐近极小极大检测边界。

定理 2.3 (最大间隔作为精确的渐近极小极大检测边界)**.** *固定检验水平 $\alpha \in (0,1)$ 与 $a \in (0,1]$。令 $s^-, s^+ : [0,1] \to [0,1]$ 分别表示改进前与改进后的性能曲线。对基准 B，令 $\Pi^*_\alpha(B; w, a, k)$ 表示：基于每道基准题 k 次重复样本、用于检验*

$$H_0 :\ s^- = s^+ \qquad \text{对} \qquad H_1 :\ \exists \text{ 区间 } I \subset [0,1],\ |I| = w,\ s^+(z) - s^-(z) \ge a \ \ \forall z \in I.$$

的水平 α 检验的极小极大最坏情形功效。

1. *若 $w \le G(B)$，则对每个 $k \in \mathbb{N}$，有 $\Pi^*_\alpha(B; w, a, k) = \alpha$。*
2. *若 $w > G(B)$，则 $\lim_{k\to\infty} \Pi^*_\alpha(B; w, a, k) = 1$。*

因此，$G(B)$ 精确刻画了基准 B 的渐近极小极大检测边界。

定理 2.3 表明，基准的离散几何诱导出一个尖锐的可检测性相变。若局部改进的宽度不超过相邻难度点的最大间隔，则无论重复评测多少次，任何水平 α 的检验都无法取得非平凡的最坏情形功效。换言之，在最坏情形下，这样的改进对基准可以完全不可见。一旦改进宽度超过最大间隔，重复评测最终可以使该信号可检测。在这个意义上，$G(B)$ 刻画了基准 B 固有的局部分辨率极限。完整证明见附录 B.2。

3 当前基准的实证诊断

我们用前文提出的两个指标，分析一组来自不同领域、被广泛使用的基准。图 2 给出难度估计与指标计算流程的概览。具体而言，我们考虑涵盖数学、编程、智能体任务、逻辑、科学、指令遵循与医学的 **25** 个常用基准。这些基准的详细信息见附录 C.1。

3.1 难度估计与指标计算

方法：项目反应理论。 为估计基准题目难度，人们可能会直接使用每道题在各模型上的平均失败率 [69, 60, 66]。然而，题目难度本质上相对于模型能力：它不仅应取决于有多少模型答错该题，还应取决于答错或答对该题的模型有多强。因此我们使用项目反应理论（IRT）。它是一个成熟的心理测量框架 [35, 50]，已被广泛用于 LLM 基准分析中的难度估计 [12, 53, 20, 25, 48, 74]。IRT 将模型解出一道题的概率建模为模型能力与题目难度的函数。在常用的单参数 logistic 模型（1PL）中，每个模型 j 被赋予能力参数 θ_j，每道题 i 被赋予难度参数 b_i。模型 j 正确解出题目 i 的概率建模为

$$\Pr(Y_{ij} = 1) = \sigma(\theta_j - b_i),$$

其中 $\sigma(\cdot)$ 为 logistic 函数。直观上，b_i 越大的题目需要越高的模型能力才能被正确解出，因此估计得到的 b_i 提供了题目难度的自然度量。对选择题基准，上述模型可以自然地用猜测参数加以扩展。

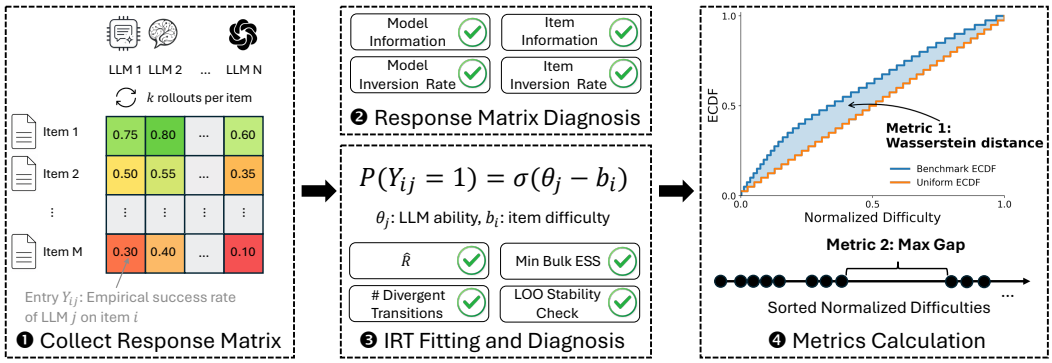

图 2: **基准难度估计与指标计算流程概览。**我们收集多个 LLM 在基准题目上的经验成功率，诊断响应矩阵，拟合 1PL IRT 模型以估计题目难度，进行拟合后的 IRT 诊断，并在归一化难度分布上计算两个指标。

实践中，难度估计首先收集多个模型在基准题目上的表现，形成响应矩阵 $Y \in \mathbb{R}^{n \times m}$，其中 Y_{ij} 表示模型 j 在题目 i 上的经验成功率。随后通过拟合 IRT 模型所诱导的似然，估计潜在能力 $\{\theta_j\}_{j=1}^{m}$ 与题目难度 $\{b_i\}_{i=1}^{n}$。为确保难度估计可靠，我们采取若干实际措施，包括**审慎的模型选择**与**严格的 IRT 拟合诊断**。

模型选择。 准确的难度估计需要能力水平多样的模型。为确保充分的能力覆盖，我们有意选择跨越宽能力范围的模型。对非智能体基准，我们依据 Text Arena 的公开排行榜[1] 选择 12 个 LLM，参数规模从 1.7B 到 397B。模型首先按跨多个领域汇总的总体能力排序，再沿该排名划分为若干近似等长的区间。我们通过从每个区间选取一个模型进行分层抽样，并额外纳入排名顶部与底部的若干模型，以更好地覆盖能力谱的两端。每个被选模型在每道基准题上最多进行 32 次 rollout，使用模型推荐的 temperature 与 top-p。对智能体基准，任务通常需要较强的专有模型。因此我们依赖 HAL [24] 的评测结果，它报告了 15–66 个最先进闭源 LLM 在智能体任务基准上的表现。模型的详细信息见附录 C.2。

IRT 拟合与诊断。 我们通过 MCMC 进行贝叶斯推断来估计 IRT 参数。为确保难度估计可靠，我们在 IRT 拟合*之前与之后*都进行一系列诊断。拟合前，我们用 4 个指标检查响应矩阵的信息量与结构一致性。拟合后，我们用 3 个标准贝叶斯诊断评估收敛性与采样质量，包括 Gelman–Rubin 统计量（$\hat{R}$）、有效样本量（ESS）以及发散转移的次数。所有基准都通过了全部 7 项诊断检查。对非智能体基准，我们进一步进行留一法（leave-one-out, LOO）稳健性分析。结果表明，我们选择的 12 个模型足以得到稳定的难度估计。为支持后续工作，我们还公开发布了这 25 个基准经过仔细整理的难度估计[2]。详细定义与诊断结果见附录 C.3。我们还在附录 C.5 中提供了与 2PL 及多维 IRT 模型的额外模型比较分析。

所提出指标的计算。 对每个基准，在估计题目难度后，我们首先将其归一化到 $[0, 1]$，并计算其经验累积分布函数（ECDF）。由于一般情况下难度空间上没有额外先验信息，我们通过计算基准经验测度与 $[0, 1]$ 上同规模经验*均匀参照*之间的 1-Wasserstein 距离来量化分布失配。在一维情形下，这等价于它们 ECDF 之间的 L_1 距离。我们按式 (1) 计算最大间隔，并同时报告五个最大相邻间隔之和作为参照指标。两个指标的后验不确定性分析见附录 C.6。

3.2 结果与分析

若干基准相对中性均匀目标存在较大偏离。 表 1 显示，25 个基准中有 10 个满足 DDM ≥ 0.10，表明其经验难度分布平均至少需要搬运整个难度范围的 10%，才能与同规模均匀参照相匹配。因此这些基准编码了很强的隐含难度加权：其汇总分数对过度代表的难度区域更敏感，对代表不足的区域更不敏感。当非均匀性与预期评测目标一致时，它本身并非问题。然而，若未指定这样的目标，高 DDM 的排行榜结果不应被解读为难度中性的比较。相反，它们反映的是在该基准经验难度加权下的比较，因此使用者应检查这一加权是否与其使用场景相关的难度分布相符。附录 D 给出一个简单的基准校准算法，用于使基准分布更接近选定的目标。

[1] https://arena.ai/leaderboard

[2] https://github.com/ASTRAL-Group/benchmark-difficulty-measure/tree/main/data/benchmarks

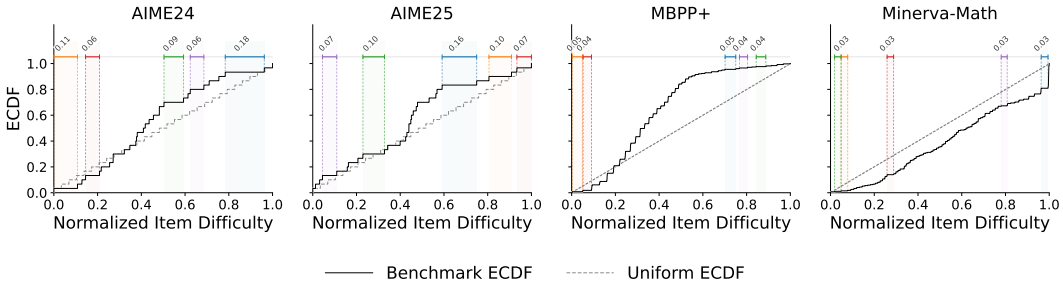

图 3: **基准难度分布。**每个面板展示一个基准归一化题目难度的 ECDF，以及中性均匀参照。彩色阴影区间标出五个最大的相邻难度间隔，标签为相应的间隔大小。更多基准示例见图 6。

表 1: **各基准上所提出指标的汇总。**DDM 表示基准经验难度分布与 $[0, 1]$ 上同规模经验均匀分布之间的 1-Wasserstein 距离。Max Gap 是归一化难度相邻点之间的最大间隔，Top-5 Sum 是五个最大此类间隔之和。# 表示基准题目数。三个指标均越低越好。高亮条目标出各指标相对较大的值：DDM ≥ 0.10，Max Gap ≥ 0.10，或 Top-5 Sum ≥ 0.30。

基准	DDM	Max Gap	Top-5 Sum	#
MATH-500	0.164	0.058	0.175	500
Minerva-Math	0.122	0.031	0.149	272
OlympiadBench	0.064	0.048	0.142	675
Gaokao2023en	0.088	0.055	0.183	385
AMC23	0.089	0.217	0.539	40
AIME24	0.077	0.179	0.502	30
AIME25	0.079	0.158	0.492	30
AIME26	0.085	0.119	0.507	30
MMLU-Pro-Biology	0.125	0.045	0.151	717
MMLU-Pro-Chemistry	0.114	0.072	0.192	1132
MMLU-Pro-Physics	0.121	0.035	0.157	1299
GPQA-Diamond	0.080	0.066	0.263	198
ScienceQA	0.178	0.045	0.175	4241

基准	DDM	Max Gap	Top-5 Sum	#
HumanEval	0.148	0.165	0.423	164
MBPP+	0.163	0.049	0.214	378
GAIA	0.084	0.051	0.218	165
CORE-Bench Hard	0.036	0.113	0.363	45
SWE-bench-Mini	0.053	0.149	0.469	50
USACO	0.080	0.082	0.354	307
IFEval	0.159	0.046	0.189	541
BBH-3 objects	0.090	0.075	0.294	250
BBH-5 objects	0.099	0.128	0.332	250
BBH-7 objects	0.077	0.059	0.279	250
ZebraLogic	0.080	0.027	0.127	1000
MedQA	0.157	0.042	0.178	1273

许多基准存在较大的局部覆盖缺口。 表 1 显示，25 个基准中有 8 个满足 Max Gap ≥ 0.10。因此，一次训练可能在未被覆盖的难度区域取得有意义的局部进展，而汇总基准分数几乎不变。这会导致有用的训练进展被低估，有希望的运行被过早放弃，计算资源被错误分配。此外，问题并不限于单一的最大间隔。我们发现 25 个基准中有 9 个满足 Top-5 Sum ≥ 0.30。例如，图 3 显示 AIME24 与 AIME25 的前 5 大间隔之和接近 0.5，尽管它们被广泛用于监测 RLVR 训练 [38, 33, 14, 70]，难度轴上仍有大段局部未分辨。

我们指出，尽管 Max Gap 本质上依赖于基准规模，这反映的是真实的覆盖限制，而不仅仅是需要消除的干扰效应：即使小基准预期会有较大间隔，它仍然是一段未被覆盖的难度区间，并且由定理 2.3，落在该区间内的局部改进在最坏情形下可能不可检测。重要的是，我们发现覆盖缺口并非仅仅是小基准的产物：拥有数百道题的基准，例如 HumanEval 与 BBH-5 objects，也表现出可观的间隔指标。这促使我们将缺口填补作为提高基准局部分辨率的一种实用且必要的途径。

4 BenchFill：面向难度的缺口填补

4.1 问题设定与方法

问题设定。 令 $B = \{x_i\}_{i=1}^n$ 为当前基准，其中每道题 x_i 具有估计难度 z_i。我们将难度排序，并考虑两道基准题之间的相邻间隔 $[z_L, z_R]$。缩小此类间隔可以提高基准的局部分辨率及其捕捉局部模型改进的能力。因此，我们的目标是得到一道有效的新题 x_{new}，其难度尽可能接近目标难度 $z^\star = (z_L + z_R)/2$，即单次插入下最能缩小该间隔的中点。新题被加入基准，而不是替换任何已有题目。默认情况下，我们对该基准的*最大*间隔应用这一过程。

一种直接做法是请人类专家按目标难度设计新题，但这一过程可能代价高昂 [51, 47]。受近期关于 LLM 辅助基准扩充的工作启发 [10, 28, 68, 67]，我们改为使用 LLM 将已有基准题*改写*为针对目标难度的新变体。这种基于改写的方法可扩展，以已有题目作为局部参照来控制难度调整，并有助于保持原始基准的格式与风格。为确保题目质量，最终入选的题目还会由人类专家进一步验证。接下来我们介绍 BenchFill，一种用于自动、面向目标难度的题目改写的“改写并标注”进化搜索算法 [54, 34]。算法 2 给出伪代码，图 4 说明该过程。

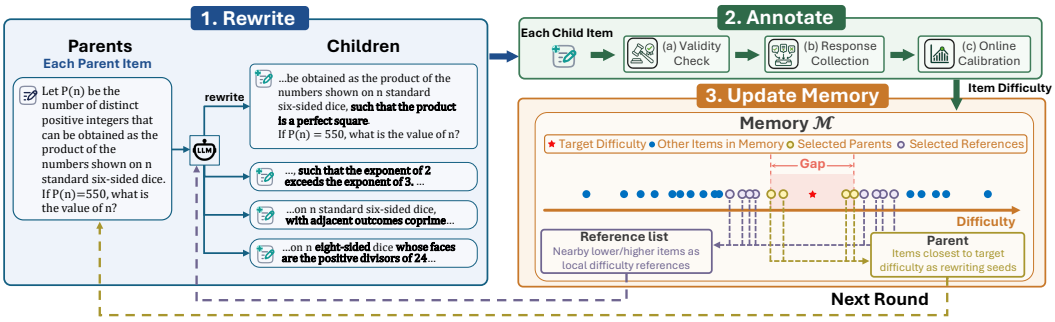

图 4: **BenchFill 概览。** BenchFill 迭代地将父题改写为子变体，标注其难度，并更新记忆以指导下一轮缺口填补。

BenchFill。 给定目标难度 $z^\star$，算法维护一个由已标注题目 – 难度对组成的记忆 $\mathcal{M}$。记忆用难度最接近所选间隔的已有基准题初始化，并在搜索过程中更新。每一轮执行一步父 – 子改写。*父题*是从 $\mathcal{M}$ 中选出、作为改写主要参照的已有题目或先前改写得到的题目，而*子题*是由父题派生的新提议变体。

在第 t 轮，我们从 $\mathcal{M}$ 中检索一小批标注难度最接近目标难度 $z^\star$ 的父题。对每个父题，改写 LLM 以该父题、目标难度以及附近题目 – 难度对的参照列表为条件。参照列表提供 $z^\star$ 附近的局部样例，通常包括略低于和略高于目标难度的题目，例如当 $z^\star = 0.55$ 时，难度为 $0.48, 0.50, 0.60$ 与 0.62 的题目。随后改写器将每个父题改写为一批子题，同时保持基准的格式与风格。

改写之后，每个子题被送入下文详述的难度标注模块，该模块返回估计难度 $\hat{z}$。我们只保留有效[3]的子题，并将其标注后的题目 – 难度对 $(x, \hat{z})$ 加回 $\mathcal{M}$。这一更新使搜索具有自适应性：每当某个改写子题比先前题目更接近 $z^\star$，它在后续轮次中就更可能被检索为父题或进入参照列表。因此，随着搜索推进，改写器以越来越与目标相关的样例为条件，而不是独立地改写每一批。经过 T 轮后，我们选择使 $|\hat{z} - z^\star|$ 最小的有效子题作为提议的缺口填补题目。在插入基准之前，最终题目须经过人类专家的仔细人工审核。

难度标注模块的细节。 对每道改写题目 x，我们在原始基准上拟合的 IRT 模型下，通过在线校准标注其难度。令 $\hat{\theta}_j$ 为模型 j 预先估计的能力。我们对 x 评估每个模型 K_j 次试验，并观测到 c_j 次正确回答。题目难度通过只拟合新题目参数来估计：

$$\hat{b}(x) = \arg\max_{b} \sum_{j=1}^{m} \Big[c_j \log \sigma(\hat{\theta}_j - b) + \big(K_j - c_j\big) \log\big(1 - \sigma(\hat{\theta}_j - b)\big) \Big],$$

其中 $\sigma(\cdot)$ 为 logistic 函数[4]。这种在线校准把每道改写题目放到与原始基准相同的 IRT 标尺上，而无需重新拟合整个模型。

4.2 实验设置与结果

实验设置。 我们在来自不同领域的 8 个代表性基准上进行缺口填补。对每个基准，我们针对三个最显著的覆盖缺口。我们使用 MiniMax-M2.7 [7] 作为改写 LLM，temperature 设为 1.0。搜索最多进行 8 轮；每一轮检索 4 个父题，将每个父题改写为 4 个子题，并提供至多 16 个附近题目 – 难度对的参照列表。作为基线，我们使用预算匹配的 best-of-N 均匀父题改写变体。更多实现细节见附录 E.1。

结果。 如表 2 所示，每个基准仅插入三道题，BenchFill 就将 Top-3 Sum 降低 21.09%–38.88%。我们也给出 oracle 结果，但仅作为参照上界，而不是可实施的缺口填补方法。所取得的降幅接近这一 oracle 参照：平均而言，BenchFill 达到 32.67% 的降幅，oracle 为 35.06%，预算匹配的均匀父题基线为 17.52%。在 AIME24、AIME25 与 AIME26 上，BenchFill 达到了 oracle 降幅。这些降幅表明，BenchFill 改善了最大未覆盖难度区域的覆盖，从而可以增强基准监测局部训练进展的能力。我们进一步报告目标偏差（Target Dev.），BenchFill 始终将 Target Dev. 控制在 0.01 以下，表明我们提出的算法能够产生接近预期难度水平的题目。有代表性的生成题目见表 13。

[3]我们使用 GPT-5.4 作为有效性评判器，核验每道改写题目所附答案是否正确。
[4]对选择题基准，我们额外纳入与原始 IRT 拟合相同的机会水平猜测参数，此处为记号简便而省略。

表 2: **缺口填补结果。**前 3 大间隔之和降幅报告相对于原始基准的相对降幅（%），越大越好。Target Dev. 是三个被填补间隔上，所选题目难度与目标难度之间的平均绝对偏差，越低越好。基线使用预算匹配的 best-of-N 均匀父题改写策略。Oracle 是一个*理想化上界*：它依次插入三道题，每道都位于当前最大间隔的中点，而不是一种实际的缺口填补方法。

基准	前 3 大间隔之和降幅（%）↑			Target Dev. ↓	
	基线	BenchFill	Oracle	基线	BenchFill
AIME24	6.90	35.57	35.57	0.057	0.005
AIME25	27.44	37.56	37.56	0.016	0.005
AIME26	17.94	33.04	33.04	0.045	0.002
AMC23	24.47	35.19	35.78	0.009	0.003
Gaokao2023en	11.45	38.88	45.47	0.152	0.004
BBH-3 objects	14.83	29.88	32.80	0.026	0.006
MMLU-Pro-Biology	22.23	30.13	36.84	0.046	0.006
IFEval	14.94	21.09	23.44	0.036	0.007
平均	17.52	32.67	35.06	0.048	0.005

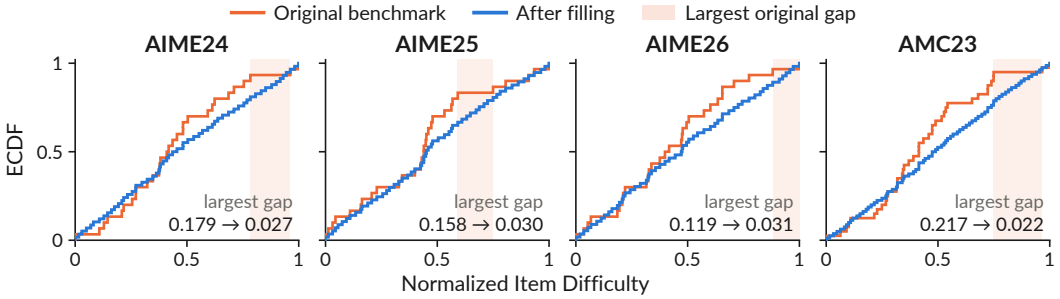

图 5: **四个基准在缺口填补前后的难度分布。**橙色与蓝色曲线分别表示应用 BenchFill 之前与之后的经验难度分布。阴影区域标出原始的最大覆盖缺口。标注数值给出填补前后的最大间隔。

4.3 经过整理的缺口填补基准

为给未来模型与训练方法的更可靠评测提供社区资源，我们进一步将 BenchFill 应用于四个覆盖缺口显著、被广泛使用的数学基准，构造其缺口填补变体：AMC23、AIME24、AIME25 与 AIME26。我们将这些基准分别从 40、30、30 与 30 道题扩展到 80、50、52 与 53 道题。所有生成题目都经过人工审核，低质量或错误的题目被丢弃。我们将所得变体发布为 **AMC23-BenchFill**、**AIME24-BenchFill**、**AIME25-BenchFill** 与 **AIME26-BenchFill**[5]。如图 5 所示，这些变体大幅缩小了原始的最大覆盖缺口，并使经验难度分布更接近均匀分布，从而在难度谱上提供更全面的覆盖。

5 相关工作

基准评测的科学。 近期一系列工作将注意力从提高排行榜分数，转向审视基准分数本身是否提供可靠的科学证据。除数据污染之外 —— 即基准测试题出现在模型训练数据中、从而可能抬高评测分数 [46, 61, 76] —— 已有研究表明，基准结果对解码、提示与实现细节敏感 [19]，并且对表面措辞或数据集缺陷十分脆弱 [44]。另有工作从信号与噪声的角度研究评测可靠性 [17]，或提出更广泛的基准质量准则，并表明广泛使用的基准在质量上差异很大 [49]。我们的工作补充了这些努力：将基准表述为难度上的经验测度，从而能够严格形式化测度失配与覆盖缺口。

IRT 及其应用。 IRT 起源于心理测量学，是教育与心理测量的一个框架 [13, 36]。在 NLP 中，[26] 将 IRT 引入系统评测，[53] 将这一视角扩展到排行榜分析。此后，IRT 成为 LLM 基准中难度感知评测的广泛基础。Easy2Hard-Bench [12] 使用 IRT 为基准题目赋予标准化的连续难度标签；它还将这些标签与人类成对判断进行验证，并报告其一致性优于基于 GPT-4 的难度标注器。[74] 使用基于 IRT 的框架分析现有 LLM 基准的测量质量。

[5] https://huggingface.co/datasets/Yifan99/BenchFill

6 结论

本文将每个基准视为难度上的一个经验测度。这一视角使我们能够形式化测度失配与覆盖缺口，并由此得到理论结果与实用诊断。我们相信，这种经验测度观点有潜力开辟新的途径，用以严格研究并重新思考基准评测。

致谢

我们感谢 Modal 通过 Modal for Academics 计算资助支持本研究。我们亦感谢 Sirui Chen 与 Junsheng Huang 富有洞见的讨论和宝贵反馈，这些讨论与反馈帮助改进了本工作。

参考文献

[1] Oriol Abril-Pla, Virgile Andreani, Colin Carroll, Larry Dong, Christopher J. Fonnesbeck, Maxim Kochurov, Ravin Kumar, Junpeng Lao, Christian C. Luhmann, Osvaldo A. Martin, Michael Osthege, Ricardo Vieira, Thomas Wiecki, and Robert Zinkov. PyMC: A modern and comprehensive probabilistic programming framework in Python. *PeerJ Computer Science*, 9(e1516), 2023.

[2] Norah Alzahrani, Hisham Alyahya, Yazeed Alnumay, Sultan Alrashed, Shaykhah Alsubaie, Yousef Almushayqih, Faisal Mirza, Nouf Alotaibi, Nora Al-Twairesh, Areeb Alowisheq, et al. When benchmarks are targets: Revealing the sensitivity of large language model leaderboards. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 13787–13805, 2024.

[3] Frank B Baker. *The basics of item response theory*. ERIC, 2001.

[4] Marthe Ballon, Andres Algaba, Brecht Verbeken, and Vincent Ginis. Estimating problem difficulty without ground truth using large language model comparisons. *arXiv preprint arXiv:2512.14220*, 2025.

[5] Andrew Bean, Simi Hellsten, Harry Mayne, Jabez Magomere, Ryan Chi, Scott A Hale, Hannah R Kirk, et al. Lingoly: A benchmark of olympiad-level linguistic reasoning puzzles in low resource and extinct languages. *Advances in Neural Information Processing Systems*, 37:26224–26237, 2024.

[6] Akhiad Bercovich, Itay Levy, Izik Golan, Mohammad Dabbah, Ran El-Yaniv, Omri Puny, Ido Galil, Zach Moshe, Tomer Ronen, Najeeb Nabwani, et al. Llama-nemotron: Efficient reasoning models. *arXiv preprint arXiv:2505.00949*, 2025.

[7] Aili Chen, Aonian Li, Baichuan Zhou, Bangwei Gong, Binyang Jiang, Boji Dan, Changqing Yu, Chao Wang, Cheng Ma, Cheng Zhong, et al. The minimax-m2 series: Mini activations unleashing max real-world intelligence. *arXiv preprint arXiv:2605.26494*, 2026.

[8] Mark Chen, Jerry Tworek, Heewoo Jun, Qiming Yuan, Henrique Ponde de Oliveira Pinto, Jared Kaplan, Harri Edwards, Yuri Burda, Nicholas Joseph, Greg Brockman, Alex Ray, Raul Puri, Gretchen Krueger, Michael Petrov, Heidy Khlaaf, Girish Sastry, Pamela Mishkin, Brooke Chan, Scott Gray, Nick Ryder, Mikhail Pavlov, Alethea Power, Lukasz Kaiser, Mohammad Bavarian, Clemens Winter, Philippe Tillet, Felipe Petroski Such, Dave Cummings, Matthias Plappert, Fotios Chantzis, Elizabeth Barnes, Ariel Herbert-Voss, William Hebgen Guss, Alex Nichol, Alex Paino, Nikolas Tezak, Jie Tang, Igor Babuschkin, Suchir Balaji, Shantanu Jain, William Saunders, Christopher Hesse, Andrew N. Carr, Jan Leike, Josh Achiam, Vedant Misra, Evan Morikawa, Alec Radford, Matthew Knight, Miles Brundage, Mira Murati, Katie Mayer, Peter Welinder, Bob McGrew, Dario Amodei, Sam McCandlish, Ilya Sutskever, and Wojciech Zaremba. Evaluating large language models trained on code. 2021.

[9] Yunxiao Chen, Xiaoou Li, Jingchen Liu, and Zhiliang Ying. Item response theory—a statistical framework for educational and psychological measurement. *Statistical Science*, 40(2):167–194, 2025.

[10] Zerui Cheng, Jiashuo Liu, Chunjie Wu, Jianzhu Yao, Pramod Viswanath, Ge Zhang, and Wenhao Huang. Vera: Verified reasoning data augmentation at scale. *arXiv preprint arXiv:2602.13217*, 2026.

[11] Herbert A David and Haikady N Nagaraja. *Order statistics*. John Wiley & Sons, 2004.

[12] Mucong Ding, Chenghao Deng, Jocelyn Choo, Zichu Wu, Aakriti Agrawal, Avi Schwarzschild, Tianyi Zhou, Tom Goldstein, John Langford, Anima Anandkumar, et al. Easy2hard-bench: Standardized difficulty labels for profiling llm performance and generalization. *Advances in Neural Information Processing Systems*, 37:44323–44365, 2024.

[13] Susan E Embretson and Steven P Reise. *Item response theory for psychologists*. Psychology Press, 2013.

[14] Daya Guo, Dejian Yang, Haowei Zhang, Junxiao Song, Peiyi Wang, Qihao Zhu, Runxin Xu, Ruoyu Zhang, Shirong Ma, Xiao Bi, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning. *arXiv preprint arXiv:2501.12948*, 2025.

[15] Chaoqun He, Renjie Luo, Yuzhuo Bai, Shengding Hu, Zhen Thai, Junhao Shen, Jinyi Hu, Xu Han, Yujie Huang, Yuxiang Zhang, et al. Olympiadbench: A challenging benchmark for promoting agi with olympiad-level bilingual multimodal scientific problems. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 3828–3850, 2024.

[16] Jujie He, Jiacai Liu, Chris Yuhao Liu, Rui Yan, Chaojie Wang, Peng Cheng, Xiaoyu Zhang, Fuxiang Zhang, Jiacheng Xu, Wei Shen, et al. Skywork open reasoner 1 technical report. *arXiv preprint arXiv:2505.22312*, 2025.

[17] David Heineman, Valentin Hofmann, Ian Magnusson, Yuling Gu, Noah A Smith, Hannaneh Hajishirzi, Kyle Lo, and Jesse Dodge. Signal and noise: A framework for reducing uncertainty in language model evaluation. *arXiv preprint arXiv:2508.13144*, 2025.

[18] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. *arXiv preprint arXiv:2103.03874*, 2021.

[19] Andreas Hochlehnert, Hardik Bhatnagar, Vishaal Udandarao, Samuel Albanie, Ameya Prabhu, and Matthias Bethge. A sober look at progress in language model reasoning: Pitfalls and paths to reproducibility. *arXiv preprint arXiv:2504.07086*, 2025.

[20] Valentin Hofmann, David Heineman, Ian Magnusson, Kyle Lo, Jesse Dodge, Maarten Sap, Pang Wei Koh, Chun Wang, Hannaneh Hajishirzi, and Noah A Smith. Fluid language model benchmarking. *arXiv preprint arXiv:2509.11106*, 2025.

[21] Jingcheng Hu, Yinmin Zhang, Qi Han, Daxin Jiang, Xiangyu Zhang, and Heung-Yeung Shum. Open-reasoner-zero: An open source approach to scaling up reinforcement learning on the base model. *arXiv preprint arXiv:2503.24290*, 2025.

[22] Carlos E Jimenez, John Yang, Alexander Wettig, Shunyu Yao, Kexin Pei, Ofir Press, and Karthik Narasimhan. Swe-bench: Can language models resolve real-world github issues? *arXiv preprint arXiv:2310.06770*, 2023.

[23] Di Jin, Eileen Pan, Nassim Oufattole, Wei-Hung Weng, Hanyi Fang, and Peter Szolovits. What disease does this patient have? a large-scale open domain question answering dataset from medical exams. *Applied Sciences*, 11(14):6421, 2021.

[24] Sayash Kapoor, Benedikt Stroebl, Peter Kirgis, Nitya Nadgir, Zachary S Siegel, Boyi Wei, Tianci Xue, Ziru Chen, Felix Chen, Saiteja Utpala, Franck Ndzomga, Dheeraj Oruganty, Sophie Luskin, Kangheng Liu, Botao Yu, Amit Arora, Dongyoon Hahm, Harsh Trivedi, Huan Sun, Juyong Lee, Tengjun Jin, Yifan Mai, Yifei Zhou, Yuxuan Zhu, Rishi Bommasani, Daniel Kang, Dawn Song, Peter Henderson, Yu Su, Percy Liang, and Arvind Narayanan. Holistic agent leaderboard: The missing infrastructure for ai agent evaluation. In *The Fourteenth International Conference on Learning Representations (ICLR)*, 2026.

[25] Alex Kipnis, Konstantinos Voudouris, Luca M Schulze Buschoff, and Eric Schulz. metabench–a sparse benchmark of reasoning and knowledge in large language models. *arXiv preprint arXiv:2407.12844*, 2024.

[26] John P Lalor, Hao Wu, and Hong Yu. Building an evaluation scale using item response theory. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, pages 648–657, 2016.

[27] Aitor Lewkowycz, Anders Andreassen, David Dohan, Ethan Dyer, Henryk Michalewski, Vinay Ramasesh, Ambrose Slone, Cem Anil, Imanol Schlag, Theo Gutman-Solo, et al. Solving quantitative reasoning problems with language models. *Advances in neural information processing systems*, 35:3843–3857, 2022.

[28] Xinyuan Li, Murong Xu, Wenbiao Tao, Hanlun Zhu, Yike Zhao, Jipeng Zhang, and Yunshi Lan. Ride: Difficulty evolving perturbation with item response theory for mathematical reasoning. *arXiv preprint arXiv:2511.04120*, 2025.

[29] Percy Liang, Rishi Bommasani, Tony Lee, Dimitris Tsipras, Dilara Soylu, Michihiro Yasunaga, Yian Zhang, Deepak Narayanan, Yuhuai Wu, Ananya Kumar, et al. Holistic evaluation of language models. *arXiv preprint arXiv:2211.09110*, 2022.

[30] Hunter Lightman, Vineet Kosaraju, Yuri Burda, Harrison Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. Let's verify step by step. In *International Conference on Learning Representations*, volume 2024, pages 39578–39601, 2024.

[31] Bill Yuchen Lin, Ronan Le Bras, Kyle Richardson, Ashish Sabharwal, Radha Poovendran, Peter Clark, and Yejin Choi. Zebralogic: On the scaling limits of llms for logical reasoning. 2025.

[32] Jiawei Liu, Chunqiu Steven Xia, Yuyao Wang, and Lingming Zhang. Is your code generated by chatgpt really correct? rigorous evaluation of large language models for code generation. *Advances in neural information processing systems*, 36:21558–21572, 2023.

[33] Mingjie Liu, Shizhe Diao, Ximing Lu, Jian Hu, Xin Dong, Yejin Choi, Jan Kautz, and Yi Dong. Prorl: Prolonged reinforcement learning expands reasoning boundaries in large language models. *arXiv preprint arXiv:2505.24864*, 2025.

[34] Shu Liu, Shubham Agarwal, Monishwaran Maheswaran, Mert Cemri, Zhifei Li, Qiuyang Mang, Ashwin Naren, Ethan Boneh, Audrey Cheng, Melissa Z Pan, et al. Evox: Meta-evolution for automated discovery. *arXiv preprint arXiv:2602.23413*, 2026.

[35] Frederic Lord. A theory of test scores. *Psychometric monographs*, 1952.

[36] Frederic M Lord. *Applications of item response theory to practical testing problems*. Routledge, 2012.

[37] Pan Lu, Swaroop Mishra, Tony Xia, Liang Qiu, Kai-Wei Chang, Song-Chun Zhu, Oyvind Tafjord, Peter Clark, and Ashwin Kalyan. Learn to explain: Multimodal reasoning via thought chains for science question answering. In *The 36th Conference on Neural Information Processing Systems (NeurIPS)*, 2022.

[38] Michael Luo, Sijun Tan, Justin Wong, Xiaoxiang Shi, William Y. Tang, Manan Roongta, Colin Cai, Jeffrey Luo, Li Erran Li, Raluca Ada Popa, and Ion Stoica. Deepscaler: Surpassing o1-preview with a 1.5b model by scaling rl. `https://pretty-radio-b75.notion.site/DeepScaleR-Surpassing-O1-Preview-with-a-1-5B-Model-by-Scaling-RL-19681902c1468005bed8ca303013a4e2`, 2025. Notion Blog.

[39] Mathematical Association of America. 2023 American Mathematics Competitions 12 (AMC 12). `https://maa.org/student-programs/amc/`, 2023. Accessed 2026-04-25.

[40] Mathematical Association of America. 2024 American Invitational Mathematics Examination (AIME). `https://maa.org/maa-invitational-competitions/`, 2024. Accessed 2026-04-25.

[41] Mathematical Association of America. 2025 American Invitational Mathematics Examination (AIME). `https://maa.org/maa-invitational-competitions/`, 2025. Accessed 2026-04-25.

[42] Mathematical Association of America. 2026 American Invitational Mathematics Examination (AIME). `https://maa.org/maa-invitational-competitions/`, 2026. Accessed 2026-04-25.

[43] Grégoire Mialon, Clémentine Fourrier, Thomas Wolf, Yann LeCun, and Thomas Scialom. Gaia: a benchmark for general ai assistants. In *International Conference on Learning Representations*, volume 2024, pages 9025–9049, 2024.

[44] Seyed Mahed Mousavi, Edoardo Cecchinato, Lucia Hornikova, and Giuseppe Riccardi. Garbage in, reasoning out? why benchmark scores are unreliable and what to do about it. In *Findings of the Association for Computational Linguistics: EACL 2026*, pages 1747–1759, 2026.

[45] Aidar Myrzakhan, Sondos Mahmoud Bsharat, and Zhiqiang Shen. Open-llm-leaderboard: From multi-choice to open-style questions for llms evaluation, benchmark, and arena. *arXiv preprint arXiv:2406.07545*, 2024.

[46] Yonatan Oren, Nicole Meister, Niladri Chatterji, Faisal Ladhak, and Tatsunori Hashimoto. Proving test set contamination in black-box language models. In *International Conference on Learning Representations*, volume 2024, pages 16354–16372, 2024.

[47] Long Phan, Alice Gatti, Ziwen Han, Nathaniel Li, Josephina Hu, Hugh Zhang, Chen Bo Calvin Zhang, Mohamed Shaaban, John Ling, Sean Shi, et al. Humanity's last exam. *arXiv preprint arXiv:2501.14249*, 2025.

[48] Felipe Maia Polo, Lucas Weber, Leshem Choshen, Yuekai Sun, Gongjun Xu, and Mikhail Yurochkin. tinybenchmarks: evaluating llms with fewer examples. *arXiv preprint arXiv:2402.14992*, 2024.

[49] Qi Qian, Chengsong Huang, Jingwen Xu, Changze Lv, Muling Wu, Wenhao Liu, Xiaohua Wang, Zhenghua Wang, Zisu Huang, Muzhao Tian, et al. Benchmark^ 2: Systematic evaluation of llm benchmarks. *arXiv preprint arXiv:2601.03986*, 2026.

[50] Georg Rasch. *Probabilistic models for some intelligence and attainment tests.* ERIC, 1993.

[51] David Rein. Can good benchmarks contain mistakes?, 2024.

[52] David Rein, Betty Li Hou, Asa Cooper Stickland, Jackson Petty, Richard Yuanzhe Pang, Julien Dirani, Julian Michael, and Samuel R Bowman. Gpqa: A graduate-level google-proof q&a benchmark. In *First conference on language modeling*, 2024.

[53] Pedro Rodriguez, Joe Barrow, Alexander Miserlis Hoyle, John P Lalor, Robin Jia, and Jordan Boyd-Graber. Evaluation examples are not equally informative: How should that change nlp leaderboards? In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 4486–4503, 2021.

[54] Asankhaya Sharma. Openevolve: an open-source evolutionary coding agent, 2025. *URL https://github. com/codelion/openevolve*.

[55] Quan Shi, Michael Tang, Karthik Narasimhan, and Shunyu Yao. Can language models solve olympiad programming? *arXiv preprint arXiv:2404.10952*, 2024.

[56] Zachary S Siegel, Sayash Kapoor, Nitya Nadgir, Benedikt Stroebl, and Arvind Narayanan. Core-bench: Fostering the credibility of published research through a computational reproducibility agent benchmark. *arXiv preprint arXiv:2409.11363*, 2024.

[57] Klaas Sijtsma and Bas T Hemker. Nonparametric polytomous irt models for invariant item ordering, with results for parametric models. *Psychometrika*, 63(2):183–200, 1998.

[58] Klaas Sijtsma and Brian W Junker. A survey of theory and methods of invariant item ordering. *British Journal of Mathematical and Statistical Psychology*, 49(1):79–105, 1996.

[59] Charlotte Siska, Katerina Marazopoulou, Melissa Ailem, and James Bono. Examining the robustness of llm evaluation to the distributional assumptions of benchmarks. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 10406–10421, 2024.

[60] Yifan Sun, Jingyan Shen, Yibin Wang, Tianyu Chen, Zhendong Wang, Mingyuan Zhou, and Huan Zhang. Improving data efficiency for llm reinforcement fine-tuning through difficulty-targeted online data selection and rollout replay. *Advances in Neural Information Processing Systems*, 38:173449–173476, 2026.

[61] Yifan Sun, Han Wang, Dongbai Li, Gang Wang, and Huan Zhang. The emperor's new clothes in benchmarking? a rigorous examination of mitigation strategies for llm benchmark data contamination. In *International Conference on Machine Learning*, 2025.

[62] Mirac Suzgun, Nathan Scales, Nathanael Schärli, Sebastian Gehrmann, Yi Tay, Hyung Won Chung, Aakanksha Chowdhery, Quoc V Le, Ed H Chi, Denny Zhou, and Jason Wei. Challenging big-bench tasks and whether chain-of-thought can solve them. *arXiv preprint arXiv:2210.09261*, 2022.

[63] Cédric Villani et al. *Optimal transport: old and new*, volume 338. Springer, 2009.

[64] Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. Glue: A multi-task benchmark and analysis platform for natural language understanding. In *Proceedings of the 2018 EMNLP workshop BlackboxNLP: Analyzing and interpreting neural networks for NLP*, pages 353–355, 2018.

[65] Yubo Wang, Xueguang Ma, Ge Zhang, Yuansheng Ni, Abhranil Chandra, Shiguang Guo, Weiming Ren, Aaran Arulraj, Xuan He, Ziyan Jiang, et al. Mmlu-pro: A more robust and challenging multi-task language understanding benchmark. *Advances in Neural Information Processing Systems*, 37:95266–95290, 2024.

[66] Liang Wen, Yunke Cai, Fenrui Xiao, Xin He, Qi An, Zhenyu Duan, Yimin Du, Junchen Liu, Lifu Tang, Xiaowei Lv, et al. Light-r1: Curriculum sft, dpo and rl for long cot from scratch and beyond. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 6: Industry Track)*, pages 318–327, 2025.

[67] Chunqiu Steven Xia, Yinlin Deng, and Lingming Zhang. Top leaderboard ranking= top coding proficiency, always? evoeval: Evolving coding benchmarks via llm. *arXiv preprint arXiv:2403.19114*, 2024.

[68] Jiahao Ying, Yixin Cao, Yushi Bai, Qianru Sun, Bo Wang, Wei Tang, Zhaojun Ding, Yizhe Yang, Xuanjing Huang, and Shuicheng Yan. Automating dataset updates towards reliable and timely evaluation of large language models. *Advances in Neural Information Processing Systems*, 37:17106–17132, 2024.

[69] Qiying Yu, Zheng Zhang, Ruofei Zhu, Yufeng Yuan, Xiaochen Zuo, Yu Yue, Weinan Dai, Tiantian Fan, Gaohong Liu, Lingjun Liu, et al. Dapo: An open-source llm reinforcement learning system at scale. *arXiv preprint arXiv:2503.14476*, 2025.

[70] Yu Yue, Yufeng Yuan, Qiying Yu, Xiaochen Zuo, Ruofei Zhu, Wenyuan Xu, Jiaze Chen, Chengyi Wang, TianTian Fan, Zhengyin Du, et al. Vapo: Efficient and reliable reinforcement learning for advanced reasoning tasks. *arXiv preprint arXiv:2504.05118*, 2025.

[71] Junyu Zhang, Yifan Sun, Tianang Leng, Jingyan Shen, Liu Ziyin, Paul Pu Liang, and Huan Zhang. When reasoning meets its laws. *arXiv preprint arXiv:2512.17901*, 2025.

[72] Xiaotian Zhang, Chunyang Li, Yi Zong, Zhengyu Ying, Liang He, and Xipeng Qiu. Evaluating the performance of large language models on gaokao benchmark. *arXiv preprint arXiv:2305.12474*, 2023.

[73] Ziqian Zhang, Xingjian Hu, Yue Huang, Kai Zhang, Ruoxi Chen, Yixin Liu, Qingsong Wen, Kaidi Xu, Xiangliang Zhang, Neil Zhenqiang Gong, et al. Rankllm: Weighted ranking of llms by quantifying question difficulty. *arXiv preprint arXiv:2602.12424*, 2026.

[74] Hongli Zhou, Hui Huang, Ziqing Zhao, Lvyuan Han, Huicheng Wang, Kehai Chen, Muyun Yang, Wei Bao, Jian Dong, Bing Xu, et al. Lost in benchmarks? rethinking large language model benchmarking with item response theory. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 40, pages 35085–35093, 2026.

[75] Jeffrey Zhou, Tianjian Lu, Swaroop Mishra, Siddhartha Brahma, Sujoy Basu, Yi Luan, Denny Zhou, and Le Hou. Instruction-following evaluation for large language models. *arXiv preprint arXiv:2311.07911*, 2023.

[76] Kaijie Zhu, Jindong Wang, Qinlin Zhao, Ruochen Xu, and Xing Xie. Dynamic evaluation of large language models by meta probing agents. *arXiv preprint arXiv:2402.14865*, 2024.

[77] Yubo Zhu, Dongrui Liu, Zecheng Lin, Wei Tong, Sheng Zhong, and Jing Shao. The llm already knows: Estimating llm-perceived question difficulty via hidden representations. In *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, pages 1160–1176, 2025.

A 讨论

A.1 更广泛的影响

本工作旨在提高基准评测的可靠性与透明度。通过诊断分布失配与覆盖缺口，我们的方法可以帮助研究者更好地理解基准分数何时为模型比较和训练进展监测提供忠实证据。更可靠的评测可能支持更透明的模型比较和更有依据的基准设计。由于本工作聚焦于基准分析，而非模型部署或数据收集，我们预计不会产生直接的负面社会影响。

A.2 局限性与未来工作

本工作建立基准评测的测度论观点，并用它刻画两个核心问题：测度失配与覆盖缺口。我们的目标不是穷尽这一观点的全部后果，而是表明基准评测可以通过基准所诱导的经验难度测度的几何来研究。我们相信，这一视角为研究基准评测开辟了更广阔的方向：额外的基准失效与设计目标都可以表述为所诱导难度测度的性质。

此外，我们当前的框架主要是事后的：给定一个已有基准，我们估计其难度分布，诊断测度失配与覆盖缺口，并通过有针对性的题目插入来缩小显著缺口。一个自然的下一步是把这一视角推进到基准构造阶段本身。与其只在基准建成之后审计失配与覆盖，基准开发者可以从一开始就主动设计所诱导的难度结构，目标是使基准测度与预期评测目标对齐，同时沿难度轴保持高局部分辨率。我们将此视为难度感知基准设计的一个有前景的方向。

A.3 扩展相关工作

难度估计。 先前工作常常从人类判断或基准元数据中导出难度标签。例如，MATH [18] 用五个难度级别标注问题，GPQA [52] 收集事后的专家难度评分，LingOly [5] 包含五个级别的人类难度。此类标签在大规模上获取代价高昂，而且它们主要反映人类感知的难度，而不是当前 LLM 在这些题目上表现出的难度。近期工作探索了其他估计策略。[77] 从隐藏表示估计 LLM 所感知的题目难度。[4] 让 LLM 做成对难度判断，并用 Bradley – Terry 分数加以汇总。EIP [73] 则从模型–题目二部图上观测到的成功与失败，联合推断题目难度与模型能力。作为补充，LoRe [71] 研究内在问题复杂度，其定义为解决问题所需的最少计算步数。在这些方法中，IRT 仍是难度感知评测的常见基础，因为它提供了一个有原则的概率框架，可以直接从响应数据联合建模题目难度与模型能力 [9]。

B 理论结果与证明

B.1 测度失配

我们首先重述定理 2.1 并给出相应证明。

定理 B.1 (分布失配控制分数扭曲与排名稳定性)**.** *设性能差函数 Δ 是 L-Lipschitz 的，即*

$$|\Delta(z) - \Delta(y)| \le L|z - y|, \qquad \forall z, y \in [0, 1].$$

则

$$\big|D_B(\theta', \theta) - D_\mu(\theta', \theta)\big| \le L\, W_1(\nu_B, \mu).$$

因此，若

$$|D_\mu(\theta', \theta)| > L\, W_1(\nu_B, \mu),$$

则

$$\operatorname{sign}\big(D_B(\theta', \theta)\big) = \operatorname{sign}\big(D_\mu(\theta', \theta)\big),$$

从而基准所诱导的排序与目标排序一致，即不会发生排名翻转。

证明. 任取耦合 $\pi \in \Pi(\nu_B, \mu)$。由于 π 的边缘分布为 ν_B 与 μ，可以写成

$$D_B(\theta', \theta) - D_\mu(\theta', \theta) = \int \Delta(z)\, d\nu_B(z) - \int \Delta(y)\, d\mu(y) = \int_{[0,1]^2} \big(\Delta(z) - \Delta(y)\big)\, d\pi(z, y).$$

取绝对值并利用 Δ 的 Lipschitz 性质，得到

$$\big|D_B(\theta', \theta) - D_\mu(\theta', \theta)\big| \le \int_{[0,1]^2} |\Delta(z) - \Delta(y)|\, d\pi(z, y) \le L \int_{[0,1]^2} |z - y|\, d\pi(z, y).$$

由于这对每个耦合 $\pi \in \Pi(\nu_B, \mu)$ 都成立，对 π 取下确界得到

$$\big|D_B(\theta', \theta) - D_\mu(\theta', \theta)\big| \le L\, W_1(\nu_B, \mu).$$

若 $D_\mu(\theta',\theta) > 0$，则

$$D_B(\theta',\theta) \geq D_\mu(\theta',\theta) - \big|D_B(\theta',\theta) - D_\mu(\theta',\theta)\big| \geq D_\mu(\theta',\theta) - L\,W_1(\nu_B,\mu) > 0.$$

因此 $D_B(\theta',\theta) > 0$。情形 $D_\mu(\theta',\theta) < 0$ 是对称的。故 $D_B(\theta',\theta)$ 与 $D_\mu(\theta',\theta)$ 必须同号，从而不会发生排名翻转。 □

重复采样下的有限样本评测。 实践中，条件均值 $s_\theta(z)$ 并不能被直接观测。相反，基准分数由模型输出的有限次重复样本估计。对难度水平为 z_i 的第 i 道基准题，以及每次独立试验 $r \in \{1,\dots,k\}$，令

$$Y_{i,r}^{\theta} \in [0,1]$$

表示模型 θ 在第 r 次样本上的观测分数，且

$$\mathbb{E}\Big[Y_{i,r}^{\theta} \mid z_i\Big] = s_\theta(z_i).$$

定义 k 样本基准分数为

$$\widehat{S}_{B,k}(\theta) := \frac{1}{nk}\sum_{i=1}^{n}\sum_{r=1}^{k} Y_{i,r}^{\theta},$$

相应的观测性能差为

$$\widehat{D}_{B,k}(\theta',\theta) := \widehat{S}_{B,k}(\theta') - \widehat{S}_{B,k}(\theta).$$

定理 B.2 (重复采样下的有限样本分数扭曲与排序稳定性)**.** *设性能差函数 Δ 是 L-Lipschitz 的。假设在给定难度水平 $z_1,\dots,z_n$ 的条件下，随机变量族*

$$\Big\{Y_{i,r}^{\theta},\, Y_{i,r}^{\theta'}\Big\}_{i=1,\dots,n;\, r=1,\dots,k}$$

相互独立，且每个变量取值于 $[0,1]$。则对任意 $\delta \in (0,1)$，以至少 $1-\delta$ 的概率，有

$$\big|\widehat{D}_{B,k}(\theta',\theta) - D_\mu(\theta',\theta)\big| \leq L\,W_1(\nu_B,\mu) + \sqrt{\frac{2\log(2/\delta)}{nk}}.$$

因此，若

$$|D_\mu(\theta',\theta)| > L\,W_1(\nu_B,\mu) + \sqrt{\frac{2\log(2/\delta)}{nk}},$$

则以至少 $1-\delta$ 的概率，有

$$\operatorname{sign}\big(\widehat{D}_{B,k}(\theta',\theta)\big) = \operatorname{sign}\big(D_\mu(\theta',\theta)\big),$$

从而不会发生观测到的排名翻转。

证明. 我们首先将误差分解为

$$\widehat{D}_{B,k}(\theta',\theta) - D_\mu(\theta',\theta) = \Big(\widehat{D}_{B,k}(\theta',\theta) - D_B(\theta',\theta)\Big) + \Big(D_B(\theta',\theta) - D_\mu(\theta',\theta)\Big).$$

因此，

$$\big|\widehat{D}_{B,k}(\theta',\theta) - D_\mu(\theta',\theta)\big| \leq \big|\widehat{D}_{B,k}(\theta',\theta) - D_B(\theta',\theta)\big| + \big|D_B(\theta',\theta) - D_\mu(\theta',\theta)\big|.$$

第二项是确定性的，并且由定理 2.1，满足

$$\big|D_B(\theta',\theta) - D_\mu(\theta',\theta)\big| \leq L\,W_1(\nu_B,\mu).$$

剩下的是界定第一项。定义

$$Z_{i,r} := Y_{i,r}^{\theta'} - Y_{i,r}^{\theta}.$$

由于 $Y_{i,r}^{\theta'}, Y_{i,r}^{\theta} \in [0,1]$，我们有

$$Z_{i,r} \in [-1,1].$$

此外，在给定 z_i 的条件下，

$$\mathbb{E}[Z_{i,r} \mid z_i] = \mathbb{E}[Y_{i,r}^{\theta'} \mid z_i] - \mathbb{E}[Y_{i,r}^{\theta} \mid z_i] = s_{\theta'}(z_i) - s_\theta(z_i) = \Delta(z_i).$$

因此

$$\widehat{D}_{B,k}(\theta',\theta) - D_B(\theta',\theta) = \frac{1}{nk}\sum_{i=1}^{n}\sum_{r=1}^{k}\Big(Z_{i,r} - \Delta(z_i)\Big).$$

在给定 $z_1,\dots,z_n$ 的条件下，变量 $\{Z_{i,r}\}$ 相互独立，且每个都落在 $[-1,1]$ 中。对任意 $t > 0$，条件地应用 Hoeffding 不等式得到

$$\mathbb{P}\Big(\,\big|\widehat{D}_{B,k}(\theta',\theta) - D_B(\theta',\theta)\big| \geq t \;\Big|\; z_1,\dots,z_n\Big) \leq 2\exp\!\left(-\frac{nk\,t^2}{2}\right).$$

取

$$t = \sqrt{\frac{2\log(2/\delta)}{nk}}$$

则以至少 $1-\delta$ 的概率给出

$$\left|\widehat{D}_{B,k}(\theta',\theta) - D_B(\theta',\theta)\right| \le \sqrt{\frac{2\log(2/\delta)}{nk}}.$$

将该界与上面的确定性界合并，即证

$$\left|\widehat{D}_{B,k}(\theta',\theta) - D_\mu(\theta',\theta)\right| \le L\,W_1(\nu_B,\mu) + \sqrt{\frac{2\log(2/\delta)}{nk}}$$

以至少 $1-\delta$ 的概率成立。

对第二个结论，若

$$|D_\mu(\theta',\theta)| > L\,W_1(\nu_B,\mu) + \sqrt{\frac{2\log(2/\delta)}{nk}},$$

则上述不等式意味着 $\widehat{D}_{B,k}(\theta',\theta)$ 不能越过零，因此它必须与 $D_\mu(\theta',\theta)$ 同号。故不会发生观测到的排名翻转。 □

无先验信息时，均匀分布作为有原则的目标分布。 下面的结果将均匀分布形式化为一种有原则的默认目标：当对性能差沿难度轴出现的位置没有先验知识时。我们考虑一种不可知设定，其中带符号的性能差 Δ 在 $[0,1]$ 上具有固定的平均水平 ρ，但其位置除此之外不受限制。对候选目标分布 μ，量 $V_\rho(\mu)$ 衡量在 μ 下最坏情形所保留的差的大小。下面的定理表明，均匀分布是在最坏情形下仍保留完整平均差 ρ 的唯一选择。

定理 B.3 (完全不确定下，均匀目标是唯一的极大极小选择)**.** *令*

$$\mathcal{F}_\rho := \left\{\Delta : [0,1] \to [-1,1] \text{ 可测} : \int_0^1 \Delta(z)\,dz = \rho\right\}, \qquad V_\rho(\mu) := \inf_{\Delta\in\mathcal{F}_\rho} \int \Delta(z)\,d\mu(z),$$

其中 $\rho \in (-1,1)$ 且 $\mu \in \mathcal{P}([0,1])$。则

$$\sup_{\mu\in\mathcal{P}([0,1])} V_\rho(\mu) = \rho$$

且唯一的最大化子是均匀分布 $\lambda = \mathrm{Unif}[0,1]$。

证明. 令

$$\beta := \frac{1+\rho}{2} \in (0,1).$$

对任意可测函数 $\Delta : [0,1] \to [-1,1]$，定义

$$G(z) := \frac{\Delta(z)+1}{2}.$$

则 $G : [0,1] \to [0,1]$ 可测，且

$$\int_0^1 G(z)\,dz = \frac{1}{2}\int_0^1 \Delta(z)\,dz + \frac{1}{2}.$$

因此，$\Delta \in \mathcal{F}_\rho$ 当且仅当

$$G : [0,1] \to [0,1] \qquad \text{且} \qquad \int_0^1 G(z)\,dz = \beta.$$

于是，对任意 $\mu \in \mathcal{P}([0,1])$,

$$V_\rho(\mu) = \inf_{\Delta\in\mathcal{F}_\rho} \int \Delta(z)\,d\mu(z) = \inf_{G:\,[0,1]\to[0,1],\,\int_0^1 G(z)\,dz=\beta} \int (2G(z)-1)\,d\mu(z).$$

由于 μ 是概率测度,

$$V_\rho(\mu) = 2 \inf_{G:\,[0,1]\to[0,1],\,\int_0^1 G(z)\,dz=\beta} \int G(z)\,d\mu(z) - 1.$$

定义

$$U_\beta(\mu) := \inf_{G:\,[0,1]\to[0,1],\,\int_0^1 G(z)\,dz=\beta} \int G(z)\,d\mu(z).$$

则

$$V_\rho(\mu) = 2U_\beta(\mu) - 1.$$

现在刻画 $\sup_{\mu\in\mathcal{P}([0,1])} U_\beta(\mu)$。

首先，若 $\mu = \lambda = \mathrm{Unif}[0,1]$，则对每个可允许的 G，

$$\int G(z)\,d\mu(z) = \int_0^1 G(z)\,dz = \beta,$$

故

$$U_\beta(\lambda) = \beta.$$

因此

$$\sup_{\mu\in\mathcal{P}([0,1])} U_\beta(\mu) \ge \beta.$$

接下来固定任意 $\mu \in \mathcal{P}([0,1])$。由 Lebesgue 分解定理，可以写成

$$\mu = f(z)\,dz + \mu_s,$$

其中 $f \ge 0$ 可积且 $\mu_s \perp dz$。令

$$m := \int_0^1 f(z)\,dz = \mu_{\mathrm{ac}}([0,1]) \le 1.$$

由于 μ_s 关于 Lebesgue 测度奇异，存在可测集 $N \subseteq [0,1]$ 使得

$$|N| = 0 \qquad \text{且} \qquad \mu_s([0,1]\setminus N) = 0.$$

于是，对任意在 N 上取零的可允许 G，我们有

$$\int G(z)\,d\mu_s(z) = 0.$$

因此，

$$U_\beta(\mu) \le \inf_{\substack{0\le G\le 1,\ \int_0^1 G(z)\,dz=\beta,\\ G=0 \text{ 在 } N \text{ 上}}} \int_0^1 G(z)f(z)\,dz.$$

由于 N 的 Lebesgue 测度为零，附加约束“$G=0$ 在 N 上”不影响下确界，故

$$U_\beta(\mu) \le \inf_{0\le G\le 1,\ \int_0^1 G(z)\,dz=\beta} \int_0^1 G(z)f(z)\,dz.$$

由浴缸原理，右端等于

$$\int_0^\beta f^\uparrow(u)\,du,$$

其中 $f^\uparrow$ 是 f 的非降重排。由于 $f^\uparrow$ 非降且 $\beta \in (0,1)$，

$$\frac{1}{\beta}\int_0^\beta f^\uparrow(u)\,du \le \int_0^1 f^\uparrow(u)\,du = \int_0^1 f(z)\,dz \le 1.$$

因此

$$U_\beta(\mu) \le \beta.$$

由于这对每个 $\mu \in \mathcal{P}([0,1])$ 都成立，我们得到

$$\sup_{\mu\in\mathcal{P}([0,1])} U_\beta(\mu) = \beta.$$

从而，

$$\sup_{\mu\in\mathcal{P}([0,1])} V_\rho(\mu) = 2\sup_{\mu\in\mathcal{P}([0,1])} U_\beta(\mu) - 1 = 2\beta - 1 = \rho.$$

剩下的是证明唯一性。设 $V_\rho(\mu) = \rho$。则必然有

$$U_\beta(\mu) = \beta.$$

由上面的论证，这蕴含

$$\int_0^\beta f^\uparrow(u)\,du = \beta \qquad \text{且} \qquad \int_0^1 f(z)\,dz = 1.$$

第二个条件蕴含 $\mu_s = 0$，因此 μ 关于密度 f 绝对连续。此外，

$$\frac{1}{\beta}\int_0^\beta f^\uparrow(u)\,du = 1$$

等于 $f^\uparrow$ 在整个区间 $[0,1]$ 上的平均值，该平均值同样为 1。由于 $f^\uparrow$ 非降，这仅当

$$f^\uparrow(u) = 1 \qquad \text{对几乎处处 } u \in [0,1].$$

因此对几乎处处 $z \in [0,1]$ 有 $f(z) = 1$，从而 $\mu = \lambda$。这证明了唯一性。 □

B.2 覆盖缺口

为分析局部改进能否从基准评测中被检测出来，我们将该问题表述为比较改进前后两条性能曲线的假设检验。我们考虑一对一般的改进前与改进后性能曲线

$$s^-, s^+ : [0,1] \to [0,1].$$

这里，$s^-(z)$ 与 $s^+(z)$ 分别表示改进前与改进后在难度水平 z 上的期望模型性能（例如 pass@1）。它们的差为

$$\Delta(z) := s^+(z) - s^-(z).$$

对第 i 道基准题以及每次试验 $r \in \{1, \dots, k\}$，令

$$Y_{i,r}^- \sim \text{Bernoulli}(s^-(z_i)), \qquad Y_{i,r}^+ \sim \text{Bernoulli}(s^+(z_i)).$$

我们假设，在给定难度水平与性能曲线的条件下，所有变量

$$\{Y_{i,r}^-, Y_{i,r}^+\}_{i=1,\dots,n;\ r=1,\dots,k}$$

相互独立。定义

$$\widehat{S}_{B,k}(s^-) := \frac{1}{nk} \sum_{i=1}^{n} \sum_{r=1}^{k} Y_{i,r}^-, \qquad \widehat{S}_{B,k}(s^+) := \frac{1}{nk} \sum_{i=1}^{n} \sum_{r=1}^{k} Y_{i,r}^+,$$

以及

$$\widehat{D}_{B,k}(s^+, s^-) := \widehat{S}_{B,k}(s^+) - \widehat{S}_{B,k}(s^-).$$

固定 $w \in (0,1]$ 与 $a \in (0,1]$。我们定义局部化备择类

$$\mathcal{H}_1(w,a) := \Big\{ (s^-, s^+) : \exists \text{ 区间 } I \subset [0,1],\ |I| = w,\ \text{使得 } s^+(z) - s^-(z) \geq a \ \ \forall z \in I \Big\}.$$

这里，参数 (w,a) 刻画改进模式：w 表示改进发生的难度区域宽度，a 表示该区域内改进的最小幅度。

原假设类为

$$\mathcal{H}_0 := \{(s^-, s^+) : s^- = s^+\}.$$

于是我们考虑检验问题

$$H_0 :\ (s^-, s^+) \in \mathcal{H}_0 \qquad \text{对} \qquad H_1 :\ (s^-, s^+) \in \mathcal{H}_1(w,a).$$

这一表述刻画的问题是：基准能否可靠地检测宽度为 w、幅度至少为 a 的有意义局部改进。

一个（可能随机化的）检验 ϕ 的水平至多为 $\alpha \in (0,1)$，如果

$$\sup_{(s^-,s^+) \in \mathcal{H}_0} \mathbb{E}_{s^-,s^+}[\phi] \leq \alpha.$$

它在 $\mathcal{H}_1(w,a)$ 上的最坏情形功效为

$$\inf_{(s^-,s^+) \in \mathcal{H}_1(w,a)} \mathbb{E}_{s^-,s^+}[\phi].$$

我们将极小极大最坏情形功效定义为

$$\Pi_\alpha^*(B; w, a, k) := \sup_{\phi:\ \sup_{(s^-,s^+) \in \mathcal{H}_0} \mathbb{E}_{s^-,s^+}[\phi] \leq \alpha} \ \inf_{(s^-,s^+) \in \mathcal{H}_1(w,a)} \mathbb{E}_{s^-,s^+}[\phi].$$

定理 B.4 (最大间隔作为精确的渐近极小极大检测边界)**.** *固定 $\alpha \in (0,1)$ 与 $a \in (0,1]$。*

1. *对每个 $k \in \mathbb{N}$，若 $w \leq G(B)$，则*

$$\Pi_\alpha^*(B; w, a, k) = \alpha.$$

2. *若 $w > G(B)$，则*

$$\lim_{k \to \infty} \Pi_\alpha^*(B; w, a, k) = 1.$$

因此，$G(B)$ 是基准 B 下区间局部化差异的精确渐近极小极大检测边界。

证明. 我们分别证明两部分。

第一部分：若 $w \le G(B)$，则 $\Pi^*_\alpha(B; w, a, k) = \alpha$。

由最大间隔的定义，存在指标 $j \in \{0, \dots, n\}$ 使得

$$z_{(j+1)} - z_{(j)} \ge w.$$

令

$$J := (z_{(j)}, z_{(j+1)}).$$

由于

$$|J| = z_{(j+1)} - z_{(j)} \ge w,$$

我们可以选取一个区间

$$I \subseteq J \qquad \text{使得} \qquad |I| = w.$$

任取 $c \in [0, 1-a]$，并定义

$$s^{-,\star}(z) \equiv c, \qquad s^{+,\star}(z) := c + a\,\mathbf{1}\{z \in I\}.$$

由于 $c \in [0, 1-a]$ 且 $a \in (0, 1]$，$s^{-,\star}$ 与 $s^{+,\star}$ 的取值都在 $[0, 1]$ 中。此外，

$$s^{+,\star}(z) - s^{-,\star}(z) = a \qquad \forall z \in I,$$

故

$$(s^{-,\star}, s^{+,\star}) \in \mathcal{H}_1(w, a).$$

因为区间 I 不含任何基准点，对每个 $i = 1, \dots, n$ 我们有

$$s^{-,\star}(z_i) = c, \qquad s^{+,\star}(z_i) = c.$$

因此，在 $(s^{-,\star}, s^{+,\star})$ 下，基准观测与原假设对

$$(\bar{s}, \bar{s}) \in \mathcal{H}_0 \qquad \text{其中} \qquad \bar{s}(z) \equiv c$$

具有完全相同的联合分布。事实上，在每个被观测的基准点 z_i 上，改进前与改进后的 Bernoulli 成功概率都等于 c。

现令 ϕ 为任意水平至多为 α 的检验。则

$$\mathbb{E}_{s^{-,\star}, s^{+,\star}}[\phi] = \mathbb{E}_{\bar{s}, \bar{s}}[\phi] \le \sup_{(s^-, s^+) \in \mathcal{H}_0} \mathbb{E}_{s^-, s^+}[\phi] \le \alpha.$$

因此

$$\inf_{(s^-, s^+) \in \mathcal{H}_1(w, a)} \mathbb{E}_{s^-, s^+}[\phi] \le \mathbb{E}_{s^{-,\star}, s^{+,\star}}[\phi] \le \alpha.$$

对所有水平 α 的检验取上确界，得到

$$\Pi^*_\alpha(B; w, a, k) \le \alpha.$$

对反向不等式，考虑与数据无关、以概率 α 拒绝的平凡随机化检验。它的水平恰好为 α，并且对每个备择其功效也恰好为 α。因此

$$\Pi^*_\alpha(B; w, a, k) \ge \alpha.$$

合并两个不等式，我们得到

$$\Pi^*_\alpha(B; w, a, k) = \alpha.$$

第二部分：若 $w > G(B)$，则 $\lim_{k \to \infty} \Pi^*_\alpha(B; w, a, k) = 1$。

我们构造一个显式的水平 α 检验，其最坏情形功效在 $k \to \infty$ 时趋于 1。

对每个基准点 z_i，定义经验差

$$\widehat{\Delta}_{i,k} := \frac{1}{k} \sum_{r=1}^{k} \big(Y^+_{i,r} - Y^-_{i,r}\big).$$

考虑最大值检验

$$\phi_{\max} := \mathbf{1}\left\{ \max_{1 \le i \le n} \widehat{\Delta}_{i,k} > t_{k,\alpha} \right\}, \qquad t_{k,\alpha} := \sqrt{\frac{2\log(n/\alpha)}{k}}.$$

我们首先验证 $\phi_{\max}$ 的水平至多为 α。在任意原假设对 $(s, s) \in \mathcal{H}_0$ 下，对每个固定的 i 与 r，

$$Y^+_{i,r} - Y^-_{i,r} \in [-1, 1], \qquad \mathbb{E}_{s,s}[Y^+_{i,r} - Y^-_{i,r}] = 0,$$

并且这些随机变量关于 r 相互独立。因此，由 Hoeffding 不等式，

$$\mathbb{P}_{s,s}\Big(\widehat{\Delta}_{i,k} > t\Big) \le \exp\!\left(-\frac{kt^2}{2}\right).$$

对 $i = 1, \dots, n$ 应用并集界，得到

$$\mathbb{P}_{s,s}(\phi_{\max} = 1) = \mathbb{P}_{s,s}\left(\max_{1 \le i \le n} \widehat{\Delta}_{i,k} > t_{k,\alpha}\right) \le \sum_{i=1}^{n} \mathbb{P}_{s,s}\left(\widehat{\Delta}_{i,k} > t_{k,\alpha}\right) \le n \exp\left(-\frac{k t_{k,\alpha}^2}{2}\right) = \alpha.$$

由于该界对 $(s, s) \in \mathcal{H}_0$ 一致成立，检验 $\phi_{\max}$ 的水平至多为 α。

接下来固定任意备择对 $(s^-, s^+) \in \mathcal{H}_1(w, a)$。由定义，存在区间 $I \subset [0, 1]$ 满足 $|I| = w$，使得

$$s^+(z) - s^-(z) \ge a, \qquad \forall z \in I.$$

因为 $w > G(B)$，任何长度为 w 的区间都不能与所有基准点不相交。因此，至少存在一个基准指标 $i^\star$ 使得

$$z_{i^\star} \in I.$$

对该指标，我们有

$$\mathbb{E}_{s^-,s^+}[\widehat{\Delta}_{i^\star,k}] = s^+(z_{i^\star}) - s^-(z_{i^\star}) \ge a.$$

再次由 Hoeffding 不等式，对任意 $t \in \mathbb{R}$,

$$\mathbb{P}_{s^-,s^+}\left(\widehat{\Delta}_{i^\star,k} \le t\right) \le \exp\left(-\frac{k}{2}(a - t)_+^2\right),$$

其中 $(u)_+ := \max\{u, 0\}$。取 $t = t_{k,\alpha}$ 得到

$$\mathbb{P}_{s^-,s^+}\left(\widehat{\Delta}_{i^\star,k} \le t_{k,\alpha}\right) \le \exp\left(-\frac{k}{2}(a - t_{k,\alpha})_+^2\right).$$

由于事件

$$\left\{\widehat{\Delta}_{i^\star,k} > t_{k,\alpha}\right\}$$

蕴含

$$\left\{\max_{1 \le i \le n} \widehat{\Delta}_{i,k} > t_{k,\alpha}\right\},$$

我们得到

$$\mathbb{P}_{s^-,s^+}(\phi_{\max} = 1) \ge \mathbb{P}_{s^-,s^+}\left(\widehat{\Delta}_{i^\star,k} > t_{k,\alpha}\right) \ge 1 - \exp\left(-\frac{k}{2}(a - t_{k,\alpha})_+^2\right).$$

该下界对所有 $(s^-, s^+) \in \mathcal{H}_1(w, a)$ 一致成立，故

$$\inf_{(s^-,s^+) \in \mathcal{H}_1(w,a)} \mathbb{E}_{s^-,s^+}[\phi_{\max}] \ge 1 - \exp\left(-\frac{k}{2}(a - t_{k,\alpha})_+^2\right).$$

由于极小极大功效至少是任一具体水平 α 检验的最坏情形功效,

$$\Pi_\alpha^*(B; w, a, k) \ge 1 - \exp\left(-\frac{k}{2}(a - t_{k,\alpha})_+^2\right).$$

最后，因为

$$t_{k,\alpha} = \sqrt{\frac{2\log(n/\alpha)}{k}} \longrightarrow 0 \qquad \text{当 } k \to \infty,$$

右端收敛到 1。由于按功效的定义有 $\Pi_\alpha^*(B; w, a, k) \le 1$，夹逼定理蕴含

$$\lim_{k \to \infty} \Pi_\alpha^*(B; w, a, k) = 1.$$

证毕。 □

C 难度估计细节与补充结果

C.1 基准细节

表 3 汇总了分析中使用的基准，包括其领域、样本数以及评测时每道题的 rollout 次数。

C.2 模型选择细节

对非智能体任务，我们依据 Text Arena 的总体排行榜选择模型。其评测套件覆盖多种领域，包括 `Expert`、`Hard Prompts`、`Coding`、`Math`、`Creative Writing`、`Instruction Following` 与 `Longer Query`。因此总体分数为模型在广泛任务上的能力提供了合理代理。为获得能力水平多样的模型，我们按总体分数将排行榜划分为 10 个等宽层级。然后从每个层级随机选取一个模型，并额外纳入排行榜顶部与底部各一个模型。由此得到共 12 个模型，覆盖宽广的能力谱。详细模型信息汇总于表 4。

对智能体任务，我们使用 HAL 评测平台所包含的模型。其中包括若干主要提供方的前沿专有模型，例如 Claude Sonnet 4.5、Claude Opus 4.1、GPT-5 与 Gemini 2.0 Flash。

表 3: **分析中所用基准的汇总。**为简洁起见，全文将 SWE-bench Verified (Mini) 简写为 SWE-bench-Mini，并将 BIG-Bench Hard-Logical Deduction-{3,5,7} objects 简写为 BBH-{3,5,7} objects。

基准	领域	样本数	每题 rollout 数
MATH-500 [30]	数学	500	8
Minerva-Math [27]	数学	272	8
OlympiadBench [15]	数学	675	8
Gaokao2023en [72]	数学	385	8
AMC23 [39]	数学	40	32
AIME24 [40]	数学	30	32
AIME25 [41]	数学	30	32
AIME26 [42]	数学	30	32
HumanEval [8]	编程	164	4
MBPP+ [32]	编程	378	4
GAIA [43]	智能体任务	165	1
CORE-Bench Hard [56]	智能体任务	45	1
SWE-bench Verified (Mini) [22]	智能体任务	50	1
USACO [55]	智能体任务	307	1
MMLU-Pro-Biology [65]	科学	717	4
MMLU-Pro-Chemistry [65]	科学	1132	4
MMLU-Pro-Physics [65]	科学	1299	4
GPQA-Diamond [52]	科学	198	4
ScienceQA [37]	科学	4241	4
IFEval [75]	指令遵循	541	4
BIG-Bench Hard-Logical Deduction-3 objects [62]	逻辑	250	4
BIG-Bench Hard-Logical Deduction-5 objects [62]	逻辑	250	4
BIG-Bench Hard-Logical Deduction-7 objects [62]	逻辑	250	4
ZebraLogic [31]	逻辑	1000	4
MedQA [23]	医学	1273	4

表 4: **非智能体任务所选模型汇总。**

模型	规模	提供方	Temperature	Top-p
Qwen3.5-397B-A17B	397B	Alibaba Qwen	0.6	0.95
GLM-4.6	357B	Zhipu AI	1.0	0.95
GLM-4.5-Air	110B	Zhipu AI	0.6	0.95
Qwen3-Next-80B-A3B-Instruct	80B	Alibaba Qwen	0.7	0.8
QwQ-32B	32B	Alibaba Qwen	0.6	0.95
Olmo-3.1-32B-Think	32B	Allen AI	0.6	0.95
gpt-oss-20b	20B	OpenAI	1.0	1.0
phi-4	14B	Microsoft	0.8	0.95
Llama-3.1-8B-Instruct	8B	Meta-Llama	0.6	0.9
vicuna-7b-v1.5	7B	LMSYS	0.9	0.6
Llama-3.2-3B-Instruct	3B	Meta-Llama	0.6	0.9
SmolLM2-1.7B-Instruct	1.7B	HuggingFaceTB	0.7	0.8

C.3 IRT 拟合与诊断

为获得可靠的难度估计，我们对响应矩阵和 IRT 拟合过程都进行若干诊断检查。

响应矩阵诊断。 我们用四个诊断检查每个响应矩阵。前两个，*模型信息量*与*题目信息量*，衡量矩阵沿模型维与题目维是否包含足够的判别信号 [3]。后两个，*模型逆序率*与*题目逆序率*，衡量经验响应矩阵与 1PL-IRT 所蕴含的单调结构吻合程度 [57, 58]。

形式上，对每个题目 – 模型对 (i, j)，我们将观测响应汇总为模型 j 在题目 i 上的经验成功率，定义为 $p_{ij} = n_{ij}^{\text{correct}}/n_{ij}^{\text{trials}}$。然后沿模型维与题目维汇总这些成功率：

$$p_j = \frac{1}{|\mathcal{I}|}\sum_{i\in\mathcal{I}} p_{ij}, \qquad p_i = \frac{1}{|\mathcal{J}|}\sum_{j\in\mathcal{J}} p_{ij},$$

其中 $\mathcal{I}$ 与 $\mathcal{J}$ 分别表示题目集合与模型集合。我们将模型信息量定义为 $4p_j(1-p_j)$ 在模型上的平均，将题目信息量定义为 $4p_i(1-p_i)$ 在题目上的平均。其直观含义是：若许多模型几乎解出所有题目或几乎一道都解不出，则其汇总成功率饱和，对区分模型能力贡献的信息有限。当许多题目被几乎所有模型解出或几乎没有模型解出时，情况相同。相反，接近 0.5 的汇总成功率信息量更大，因为它们对应既不饱和也不退化的模型或题目。因子 4 将该量重新缩放到 $[0, 1]$。

为评估响应矩阵是否与 1PL-IRT 所蕴含的序一致，我们首先按总体成功率对模型排序，按总体解出率对题目排序。然后计算两个逆序率。模型逆序率是有序模型对中、逐题评估时较强模型表现差于较弱模型的比例。题目逆序率是有序题目对中、逐模型评估时较易题目被解出次数少于较难题目的比例。较低的逆序率表明与 IRT 所假设的潜在序更一致。

在实验中，我们以模型信息量 ≥ 0.3、题目信息量 ≥ 0.3、模型逆序率 ≤ 0.3、题目逆序率 ≤ 0.3 作为基本阈值。通过这些检查表明矩阵包含足够信号，并且与 IRT 的序假设合理一致。

IRT 拟合。 我们用贝叶斯推断拟合 1PL-IRT 模型。对选择题基准，我们额外纳入一个猜测参数：

$$\Pr(Y_{ij} = 1) = g_i + (1 - g_i)\sigma(\theta_j - b_i),$$

其中 g_i 表示靠猜测答对题目 i 的机会水平概率。

模型能力 θ_j 与题目难度 b_i 被赋予独立的高斯先验，

$$\theta_j \sim \mathcal{N}(0, 1), \qquad b_i \sim \mathcal{N}(0, 1).$$

由于每个模型–题目对被评估多次，我们用二项似然建模正确回答的次数。后验推断使用 PyMC [1] 中实现的 No-U-Turn Sampler（NUTS）进行 MCMC。我们运行四条链，每条链 1,000 次预热迭代与 1,000 个后验样本。目标接受率设为 0.95。

我们还探索了其他先验结构以评估稳健性。特别地，我们考虑了模型能力的层次先验，

$$\theta_j \sim \mathcal{N}(\mu_\theta, \sigma_\theta^2), \qquad \mu_\theta \sim \mathcal{N}(0, 1), \quad \sigma_\theta \sim \text{HalfNormal}(1),$$

同时题目难度仍使用与上面相同的高斯先验。我们还额外测试了题目难度的层次先验，

$$b_i \sim \mathcal{N}(\mu_b, \sigma_b^2), \qquad \mu_b \sim \mathcal{N}(0, 1), \quad \sigma_b \sim \text{HalfNormal}(1),$$

模型能力则使用标准高斯先验。在这些变体之间，估计的题目难度与模型能力高度一致。因此，我们报告使用独立 $\mathcal{N}(0, 1)$ 先验这一最简单设定的结果。

IRT 诊断。 为评估收敛性与采样质量，我们监测 3 个标准 MCMC 诊断：各参数上的最大 Gelman – Rubin 统计量 $\hat{R}$、最小 bulk 有效样本量（ESS），以及发散转移的次数。$\hat{R}$ 统计量衡量链之间的一致性，接近 1 的值表示收敛良好。Bulk ESS 量化分布主体中有效独立后验样本的数目，较大的值表示估计更可靠。发散转移表明 NUTS 采样过程中可能存在数值或几何病态，零次发散转移更为理想。

诊断结果。 表 5 与表 6 汇总了所有基准的诊断结果。所有基准都通过了诊断阈值。

留一法稳健性分析。 对每个非智能体基准，我们在所选模型集合上做留一法分析，以评估基于 IRT 的难度估计的稳健性。具体而言，给定 12 个所选模型，我们将 IRT 重拟合 12 次，每次去掉一个模型，并用剩余 11 个模型重新估计题目难度。然后用 Pearson 与 Spearman 相关，将所得难度估计与使用全部 12 个模型得到的原始估计进行比较。对每个基准，我们报告 12 次留一重拟合上的平均相关与最小相关。如表 7 所示，在所有基准上，平均 Pearson 与 Spearman 相关分别至少为 0.9723 与 0.9704。即使最坏情形的留一相关仍然很高，最小 Pearson 与 Spearman 相关分别为 0.9137 与 0.9089。这些结果表明，估计的题目难度对排除任意单个模型是稳定的，支持我们选择 12 个模型足以得到稳定的难度估计。

C.4 指标计算细节

对含有 n 道题的基准，我们将其归一化难度点（min-max 归一化）与 $[0, 1]$ 上同规模的经验均匀参照进行比较。令 $z_{(1)} \leq \cdots \leq z_{(n)}$ 表示排序后的归一化难度。我们将均匀参照点定义为 n 个等宽区间的中点：

$$u_i = \frac{i - \frac{1}{2}}{n}, \qquad i = 1, \ldots, n.$$

于是 DDM 计算为

$$\text{DDM}(B) = \frac{1}{n}\sum_{i=1}^{n} |z_{(i)} - u_i|.$$

表 5: **响应矩阵诊断结果。**↑ 表示越大越好，↓ 表示越小越好。我们以模型信息量 ≥ 0.3、题目信息量 ≥ 0.3、模型逆序率 ≤ 0.3、题目逆序率 ≤ 0.3 作为响应矩阵诊断的基本阈值。所有基准都通过了这些检查。

基准	模型信息量 ↑	题目信息量 ↑	模型逆序率 ↓	题目逆序率 ↓
AMC23	0.458	0.867	0.062	0.177
AIME24	0.514	0.824	0.040	0.101
AIME25	0.515	0.806	0.057	0.118
AIME26	0.465	0.831	0.046	0.089
Gaokao2023en	0.661	0.681	0.101	0.112
HumanEval	0.546	0.675	0.165	0.205
MATH-500	0.463	0.730	0.063	0.125
MBPP+	0.665	0.636	0.226	0.235
Minerva-Math	0.724	0.554	0.174	0.107
OlympiadBench	0.715	0.663	0.106	0.093
BBH-3 objects	0.344	0.541	0.069	0.231
BBH-5 objects	0.421	0.735	0.076	0.292
BBH-7 objects	0.451	0.790	0.080	0.285
GPQA-Diamond	0.843	0.852	0.249	0.251
IFEval	0.663	0.573	0.217	0.162
MedQA	0.795	0.777	0.264	0.262
MMLU-Pro-Biology	0.617	0.632	0.172	0.160
MMLU-Pro-Chemistry	0.676	0.787	0.162	0.186
MMLU-Pro-Physics	0.687	0.787	0.176	0.195
ScienceQA	0.659	0.434	0.184	0.102
ZebraLogic	0.581	0.796	0.048	0.060
GAIA	0.879	0.739	0.251	0.178
CORE-Bench Hard	0.651	0.578	0.192	0.135
SWE-bench-Mini	0.709	0.674	0.112	0.103
USACO	0.908	0.472	0.205	0.059

这是基准经验测度与同规模经验均匀参照之间的一维 1-Wasserstein 距离

$$\lambda_n = \frac{1}{n}\sum_{i=1}^{n}\delta_{u_i}.$$

对基于间隔的指标，令 $z_{(0)} = 0$ 且 $z_{(n+1)} = 1$。最大间隔为

$$G(B) = \max_{0\leq i\leq n}\big(z_{(i+1)} - z_{(i)}\big).$$

C.5 不同难度估计模型的比较

我们的实证分析依赖标量 1PL IRT 难度估计。为评估这一建模选择是否得到响应数据支持，我们将 1PL 与更灵活的 IRT 设定进行比较，包括 2PL 与多维 IRT 模型。

我们首先用贝叶斯信息准则（Bayesian Information Criterion, BIC）比较 1PL 与 2PL，BIC 越低越好。如表 8 所示，BIC 在 25 个基准中的 21 个上选择 1PL，且往往优势很大。这表明对大多数基准，在计入模型复杂度后，增加题目特异的区分度参数并不被支持。

对其余四个 BIC 偏向 2PL 的基准，2PL 拟合表现出有问题的采样诊断，而相应的 1PL 拟合仍然表现良好。表 9 报告了这些情形的收敛诊断。例如，在 Gaokao2023en 上，2PL 拟合给出最大 $\hat{R} = 1.06$、最小 bulk ESS $= 63$ 以及 983 次发散转移，而 1PL 拟合的最大 $\hat{R} = 1.01$、最小 bulk ESS $= 569$，且没有发散转移。AIME24、AIME25 与 AMC23 也出现类似问题。因此，尽管 BIC 偶尔偏向 2PL，这些 2PL 拟合并不能提供可靠的替代难度估计。

我们还评估具有两个与三个潜在维度的多维 IRT 模型，记为 MIRT-2 与 MIRT-3。表 10 报告了 15 个较小基准上的收敛诊断。总体而言，这些多维拟合不能提供稳定的后验估计：大多数运行的最大 $\hat{R}$ 远高于 1.05 这一标准收敛阈值，且最小 bulk ESS 极小，表明混合很差。在更大的基准上，多维模型代价高得多，并且在相同贝叶斯拟合流程下未能在我们的拟合预算内可靠完成。因此，当前响应矩阵不能为我们的实证分析支持稳定的多维难度估计。

表 6: **IRT 拟合的 MCMC 诊断结果。**↑ 表示越大越好，↓ 表示越小越好。

基准	最大 $\hat{R}$ ↓	最小 Bulk ESS ↑	发散转移数 ↓
AMC23	1.01	334	0
AIME24	1.02	272	0
AIME25	1.01	246	0
AIME26	1.00	385	0
Gaokao2023en	1.01	569	0
HumanEval	1.01	826	0
MATH-500	1.01	1296	0
MBPP+	1.01	1167	0
Minerva-Math	1.01	487	0
OlympiadBench	1.01	1246	0
BBH-3 objects	1.00	1996	0
BBH-5 objects	1.01	1450	0
BBH-7 objects	1.00	1218	0
GPQA-Diamond	1.00	1437	0
IFEval	1.01	2120	0
MedQA	1.01	1733	0
MMLU-Pro-Biology	1.01	2511	0
MMLU-Pro-Chemistry	1.01	2014	0
MMLU-Pro-Physics	1.01	2002	0
ScienceQA	1.01	1757	0
ZebraLogic	1.01	1960	0
GAIA	1.00	1861	0
CORE-Bench Hard	1.01	3272	0
SWE-bench-Mini	1.00	4419	0
USACO	1.01	2102	0

总体而言，这些模型比较结果支持在本研究中使用 1PL 作为可靠的难度估计模型。更复杂的 IRT 设定在其他情形下可能有用，但我们的诊断表明，对这里分析的响应矩阵，1PL 提供了最稳定、支持最充分的难度估计。

C.6 后验不确定性分析

我们进一步量化拟合得到的 IRT 难度估计中的后验不确定性如何影响所计算的指标。对拟合 1PL 题目难度的每一次后验抽样，我们重新计算 DDM 与 Max Gap，并汇总这些指标在各次抽样上的后验变异。

在 IRT 后验不确定性下，DDM 是稳定的。 在 25 个基准上，DDM 的后验标准差通常约为 0.011，范围为 0.006–0.020。相对于 DDM 的点估计，这很小，在典型情形下大约相当于 8%–12%。因此，正文报告的 DDM 值并不是难度估计噪声的产物。

Max Gap 的不确定性更大，但覆盖缺口的结论仍然稳健。 Max Gap 具有更大的后验不确定性，这符合预期，因为它是极端次序统计量 [11]：它由题目难度之间最大的相邻间距定义，因此对局部后验扰动更敏感。其后验标准差范围为 0.017 到 0.041。然而，关于覆盖缺口的定性结论仍然稳健。为验证这一点，我们在后验难度抽样下，将观测到的 Max Gap 与同规模均匀抽样基线进行比较。在各基准上，观测 Max Gap 超过同规模均匀基线的后验概率中位数为 0.999。观测值与基线之比的中位数为 3.85×，并且在若干大基准上大得多，例如 ScienceQA 上为 18.8×，MedQA 上为 11.3×，ZebraLogic 上为 5.9×。因此，尽管 Max Gap 的精确大小带有后验不确定性，许多基准含有远超随机均匀抽样的覆盖缺口这一结论是稳健的。

C.7 补充实验细节与结果

我们的代码仓库位于：

`https://github.com/ASTRAL-Group/benchmark-difficulty-measure`.

所有实验在配备 48GB 显存的 NVIDIA L40S GPU 以及配备 96GB 显存的 NVIDIA RTX PRO 6000 Blackwell Server Edition GPU 上完成。图 6 给出图 3 中未展示的其余基准的难度分布图，可视化格式相同。

表 7: **IRT 难度估计的留一法稳健性。**对每个基准，我们先用全部 12 个模型拟合 IRT，然后每次去掉一个模型重拟合，并将所得题目难度与全量拟合比较。我们报告 12 次留一重拟合上 Pearson 与 Spearman 相关的均值与最小值。持续较高的相关表明，所选 12 个模型足以稳定估计题目难度。

基准	Pearson 均值	Pearson 最小值	Spearman 均值	Spearman 最小值
AMC23	0.9962	0.9820	0.9921	0.9484
AIME24	0.9985	0.9940	0.9977	0.9920
AIME25	0.9978	0.9904	0.9941	0.9809
AIME26	0.9979	0.9937	0.9972	0.9888
Gaokao2023en	0.9974	0.9953	0.9957	0.9905
HumanEval	0.9902	0.9771	0.9871	0.9735
MATH-500	0.9952	0.9896	0.9935	0.9844
MBPP+	0.9902	0.9751	0.9840	0.9599
Minerva-Math	0.9974	0.9951	0.9896	0.9871
OlympiadBench	0.9980	0.9953	0.9973	0.9946
BBH-3 objects	0.9766	0.9137	0.9764	0.9089
BBH-5 objects	0.9723	0.9207	0.9704	0.9162
BBH-7 objects	0.9764	0.9360	0.9745	0.9248
GPQA-Diamond	0.9941	0.9893	0.9937	0.9852
IFEval	0.9945	0.9853	0.9910	0.9806
MedQA	0.9916	0.9875	0.9861	0.9722
MMLU-Pro-Biology	0.9951	0.9894	0.9923	0.9792
MMLU-Pro-Chemistry	0.9955	0.9914	0.9936	0.9860
MMLU-Pro-Physics	0.9952	0.9907	0.9934	0.9839
ScienceQA	0.9965	0.9893	0.9869	0.9330
ZebraLogic	0.9974	0.9948	0.9966	0.9909
平均	**0.9926**	**0.9798**	**0.9897**	**0.9696**

D 基准校准

问题设定。 测度失配的视角提示了一种重新设计基准的自然方式：调整基准经验测度，使其更好地匹配目标评测分布。考虑基准

$$B = \{x_1, \ldots, x_n\},$$

其中每道题 x_i 具有估计难度 $z_i \in [0,1]$。该基准在难度轴上诱导经验测度

$$\nu_B = \frac{1}{n}\sum_{i=1}^{n} \delta_{z_i}$$

。给定目标分布 $\mu \in \mathcal{P}([0,1])$，基准校准旨在构造一个新基准 B'，使其经验测度 $\nu_{B'}$ 比 ν_B 更接近 μ。

在本工作中，我们通过剪枝来实现基准校准。具体而言，我们从原始基准中保留 k 道题，即选择子集 $A \subseteq [n]$ 且 $|A| = k$。所选题目构成校准后的基准

$$B_A = \{x_i : i \in A\},$$

其经验难度测度为

$$\nu_A = \frac{1}{k}\sum_{i \in A} \delta_{z_i}.$$

目标是选择 A，使 ν_A 更好地近似目标分布 μ，例如以 $\mathrm{DDM}(B_A; \mu) = W_1(\nu_A, \mu)$ 来衡量。

一个简单的校准算法。 我们使用一个简单的贪心分位数匹配剪枝过程，概括于算法 1。令 Q_μ 表示目标分布 μ 的分位函数。给定子集大小 k，我们首先取 μ 下 k 个等概率区间的中点，构造 k 个目标难度位置:

$$\tau_t = \frac{t - \frac{1}{2}}{k}, \qquad q_t = Q_\mu(\tau_t), \qquad t = 1, \ldots, k.$$

然后将这些目标位置匹配到已有基准题。具体而言，在将题目难度归一化到 $[0,1]$ 之后，我们遍历 $q_1, \ldots, q_k$，并选择难度最接近当前目标位置的未使用题目:

$$i_t \in \arg\min_{i \in [n] \setminus \{i_1, \ldots, i_{t-1}\}} |z_i - q_t|.$$

校准子集为 $A = \{i_1, \ldots, i_k\}$。

表 8: **全部基准上 1PL 与 2PL 的 BIC 比较。**BIC 越低越好。我们定义 $\Delta\text{BIC} = \text{BIC}_{2\text{PL}} - \text{BIC}_{1\text{PL}}$，因此正值偏向 1PL。BIC 在 25 个基准中的 21 个上选择 1PL。

基准	$\text{BIC}_{1\text{PL}}$	$\text{BIC}_{2\text{PL}}$	ΔBIC	所选
ScienceQA	126817	151726	+24909	1PL
MMLU-Pro-Physics	44290	52569	+8279	1PL
MedQA	52414	60340	+7926	1PL
ZebraLogic	22000	29319	+7319	1PL
MMLU-Pro-Chemistry	37446	44645	+7199	1PL
MMLU-Pro-Biology	21712	25399	+3687	1PL
IFEval	17614	20286	+2672	1PL
USACO	5349	7500	+2151	1PL
BBH-3 objects	5362	6958	+1596	1PL
MBPP+	14222	15778	+1556	1PL
BBH-7 objects	6838	8260	+1422	1PL
BBH-5 objects	6515	7910	+1395	1PL
GAIA	7130	8166	+1036	1PL
Minerva-Math	11865	12798	+933	1PL
GPQA-Diamond	8080	8739	+659	1PL
MATH-500	17194	17739	+545	1PL
OlympiadBench	25166	25466	+300	1PL
SWE-bench-Mini	1624	1876	+252	1PL
CORE-Bench Hard	2881	3106	+225	1PL
HumanEval	5188	5376	+188	1PL
AIME26	1358	1362	+4	1PL
Gaokao2023en	15054	14977	-77	2PL
AIME25	1593	1512	-81	2PL
AIME24	1496	1409	-87	2PL
AMC23	2607	2052	-555	2PL

表 9: **BIC 偏向 2PL 的基准上的后验诊断。**我们报告拟合参数上的最大 $\hat{R}$、最小 bulk ESS 以及发散转移次数。尽管 BIC 在这四个基准上偏向 2PL，2PL 拟合的采样诊断明显更差，而相应的 1PL 拟合仍然表现良好。

基准	1PL			2PL		
	Max $\hat{R}\downarrow$	Min Bulk ESS $\uparrow$	# Div. $\downarrow$	Max $\hat{R}\downarrow$	Min Bulk ESS $\uparrow$	# Div. $\downarrow$
Gaokao2023en	1.01	569	0	1.06	63	983
AIME25	1.01	246	0	1.02	188	18
AIME24	1.02	272	0	1.04	118	2
AMC23	1.01	334	0	1.03	146	8

D.1 实验设置

实践中，给定难度轴上的任意目标分布，我们的基准校准想法与算法 1 都可以直接应用。在本实验中，我们研究这种校准能否使单个基准产生的模型排名，与更广泛的同领域基准族更加一致。

我们考虑 $N = 8$ 个数学基准，如表 3 所示。对每个基准 B_i，我们将其视为待校准的源基准，并仅用其余基准 $\{B_j : j \neq i\}$ 构造模型的外部参照排名。这一留一设计评估：B_i 的校准版本所诱导的排名，是否与同领域其他基准得到的排名更一致。

具体地，令

$$B_i = \{x_{i1}, \ldots, x_{in_i}\}$$

为第 i 个基准，其中题目 $x_{i\ell}$ 的归一化难度为 $z_{i\ell} \in [0, 1]$。由于留一参照排名由同领域多个基准汇总而来，它较少受任一源基准特有的难度集中所束缚。因此我们用校准从源基准过度集中的难度区域剪除题目。在没有应用特定目标分布时，我们将校准目标取为均匀分布

$$\lambda = \text{Unif}[0, 1].$$

这一选择不应被理解为假定留一参照分布恰好是均匀的。相反，均匀校准提供了一种中性的去偏策略：它并不先验地偏袒任何难度区域，并且抵消那些经验质量集中在难度轴狭窄部分的基准。

我们将算法 1 以目标分布 λ 应用于 B_i，得到大小为 k_i 的校准子集 $A_i \subseteq [n_i]$。校准后的基准为

$$B_{i,A_i} = \{x_{i\ell} : \ell \in A_i\}.$$

表 10: **较小基准上多维 IRT 拟合的收敛诊断。**我们报告拟合参数上的最大 $\hat{R}$、最小 bulk ESS 以及发散转移次数。多维拟合总体上混合很差，最大 $\hat{R}$ 高而最小 bulk ESS 很小，表明它们不能提供稳定的替代难度估计。

基准	MIRT-2			MIRT-3		
	Max $\hat{R}\downarrow$	Min Bulk ESS $\uparrow$	# Div. $\downarrow$	Max $\hat{R}\downarrow$	Min Bulk ESS $\uparrow$	# Div. $\downarrow$
AIME24	1.02	202	0	1.68	6	0
AIME25	1.75	6	0	1.02	172	0
AIME26	1.54	7	0	1.44	8	0
AMC23	1.75	6	0	1.35	10	0
Minerva-Math	1.73	6	0	1.37	10	0
GPQA-Diamond	1.81	6	0	1.67	6	0
HumanEval	1.58	7	0	1.90	6	0
MBPP+	2.24	5	0	1.88	6	0
BBH-3 objects	1.78	6	0	1.26	12	0
BBH-5 objects	1.92	6	0	1.23	13	0
BBH-7 objects	1.84	6	0	1.16	20	0
CORE-Bench Hard	1.77	6	0	1.09	31	0
GAIA	1.62	7	0	1.27	12	0
SWE-bench-Mini	1.48	8	0	1.13	20	0
USACO	1.52	7	0	1.35	10	0

算法 1 分位数匹配的基准校准

输入： 归一化题目难度 $z_1, \ldots, z_n \in [0,1]$，子集大小 k，目标分位函数 Q_μ

初始化已选集合 $A \leftarrow \emptyset$ 与可用集合 $U \leftarrow [n]$

对于 $t = 1, \ldots, k$ **执行**

设定目标分位水平

$$\tau_t \leftarrow \frac{t - \frac{1}{2}}{k}$$

设定目标难度位置

$$q_t \leftarrow Q_\mu(\tau_t)$$

选择最接近的未使用题目：

$$i_t \in \arg\min_{i \in U} |z_i - q_t|$$

更新 $A \leftarrow A \cup \{i_t\}$

更新 $U \leftarrow U \setminus \{i_t\}$

结束 对于

返回 A

假设所有基准评估相同的 M 个模型。令 $S_i(m)$ 表示模型 m 在完整源基准 B_i 上的平均分数，令 $S_i(A_i, m)$ 表示其在校准子集上的平均分数。未校准排名由

$$S_i(m), \qquad m = 1, \ldots, M,$$

诱导，而校准排名由

$$S_i(A_i, m), \qquad m = 1, \ldots, M.$$

对留一参照排名，我们在其余基准上汇总模型分数：

$$S_{-i}^{\mathrm{ref}}(m) = \frac{1}{N-1} \sum_{j \neq i} S_j(m).$$

由 $S_{-i}^{\mathrm{ref}}(m)$ 诱导的排名作为源基准 B_i 的外部参照排名。

对每个源基准，我们计算源诱导排名与留一参照排名之间的 Spearman 与 Kendall 相关，包括校准前与校准后。校准后相关提高，表明把源基准剪枝到更均衡的难度分布，使其模型比较与更广泛的同领域基准族更加一致。

D.2 结果

实验结果见表 11。结果表明，我们的校准算法提高了源基准排名与留一参照排名之间的一致性。平均而言，校准将 Spearman 相关从 0.890 提高到 0.930，将 Kendall 相关从 0.802 提高到 0.848。改进在初始一致

表 11: **八个数学基准上的基准校准结果。**对每个源基准，**完整**表示原始基准，**随机**表示同等规模的 30 个随机剪枝子集的平均，**校准**表示我们的分位数匹配基准校准算法产生的校准子集。Spearman 与 Kendall 衡量与留一参照排名的一致性。我们报告 $W_1(\nu, \mathrm{Unif})$ 作为机制指标，以验证校准使所选基准测度更接近中性均匀分布。加粗值表示每个基准、每个指标上 **完整**、**随机**与 **校准** 中的最佳结果。

	Spearman ↑			**Kendall ↑**			**$W_1(\nu, \mathrm{Unif})$ ↓**		
基准	**完整**	**随机**	**校准**	**完整**	**随机**	**校准**	**完整**	**随机**	**校准**
Minerva-Math	0.601	0.649	**0.790**	0.455	0.514	**0.667**	0.122	0.115	**0.005**
MATH-500	0.930	0.942	**0.958**	0.879	0.878	**0.909**	0.164	0.165	**0.099**
Gaokao2023en	0.888	0.895	**0.951**	0.788	0.790	**0.879**	0.088	0.086	**0.029**
AIME24	**0.944**	0.942	**0.944**	**0.848**	0.847	**0.848**	0.077	0.108	**0.019**
AIME25	0.958	0.936	**0.972**	0.909	0.854	**0.915**	0.079	0.126	**0.020**
AIME26	0.949	0.950	**0.970**	0.870	0.867	**0.901**	0.085	0.108	**0.017**
AMC23	**0.937**	0.934	**0.937**	**0.848**	**0.848**	**0.848**	0.089	0.093	**0.025**
OlympiadBench	**0.916**	0.910	**0.916**	**0.818**	0.806	**0.818**	0.064	0.067	**0.008**
平均	0.890	0.895	**0.930**	0.802	0.801	**0.848**	0.096	0.109	**0.028**

性较弱的基准上尤其明显。值得注意的是，在 Minerva-Math 上，完整基准与参照排名的 Spearman 与 Kendall 相关分别只有 0.601 与 0.455，而校准将其分别提高到 0.790 与 0.667。类似地，在 Gaokao2023en 上，校准将 Spearman 从 0.888 提高到 0.951，将 Kendall 从 0.788 提高到 0.879。对其余基准，初始一致性已经很高，改进空间较小；尽管如此，校准在使用剪枝后基准的同时，始终保持了这一高水平一致性。

我们加入一个随机剪枝基线，其剪枝规模与校准子集相同，并在 30 次随机试验上取平均。随机剪枝不如校准有效：它的平均 Spearman 为 0.895，平均 Kendall 为 0.801，都低于校准子集。我们还报告 $W_1(\nu, \mathrm{Unif})$ 作为机制指标。校准在所有基准上一致地减小该距离，将平均值从 0.096 降到 0.028。相反，随机剪枝平均而言并不减小该距离，平均值为 0.109。这表明改进并非仅仅因为使用了更小的基准，而是来自选择那些经验难度测度更好地匹配中性校准目标的题目。

E BenchFill 的补充细节与实验结果

算法 2 BENCHFILL

输入： 带归一化难度的基准题 $\{(x_i, z_i)\}_{i=1}^{n}$；目标间隔 $[z_L, z_R]$；改写 LLM $\mathcal{G}$；有效性评判器 $\mathcal{J}$；IRT 评测 LLM $\{M_j\}_{j=1}^{m}$ 及其预先估计的 IRT 能力 $\{\hat{\theta}_j\}_{j=1}^{m}$；每个 LLM 的试验次数 $\{K_j\}_{j=1}^{m}$；父题数 R；每个父题的子题数 C；参照列表预算 L；最大轮数 T；归一化 $[0,1]$ 标尺上的容差 τ。

输出： 一道提议的缺口填补题目 $x^{\star}_{\text{item}}$。

设定目标难度 $z^{\star} \leftarrow (z_L + z_R)/2$。
用所选间隔附近已有的标注题目 – 难度对初始化记忆 $\mathcal{M}$。
初始化有效候选集 $\mathcal{C}_{\text{valid}} \leftarrow \emptyset$。
对于 $t = 1, \ldots, T$ **执行**
    检索父题集 $\mathcal{S}_t \subseteq \mathcal{M}$，其中至多 R 道题，其标注难度最接近 $z^{\star}$。
    用 $z^{\star}$ 附近的题目 – 难度对构造参照列表 $\mathcal{R}_t \subseteq \mathcal{M}$，满足 $|\mathcal{R}_t| \le L$；在可得时，至多一半取自低于 $z^{\star}$ 的题目，其余取自高于 $z^{\star}$ 的题目。
    对于 每个父题 $(x_p, z_p) \in \mathcal{S}_t$ **执行**
        为了提示，将 $z^{\star}$ 与 $\mathcal{R}_t$ 中显示的难度从 $[0,1]$ 重新缩放到 $[0,10]$。
        以父题、目标难度和参照列表为条件，将父题改写为 C 个子题：

$$\{x_{p,1}, \ldots, x_{p,C}\} \leftarrow \mathcal{G}(x_p, z^{\star}, \mathcal{R}_t).$$

        对于 每个子题 $x_{p,c}$ **执行**
            若 $\mathcal{J}$ 核验 $x_{p,c}$ 的参考答案正确 **则**
                对于 $j = 1, \ldots, m$ **执行**
                    用 LLM M_j 在 $x_{p,c}$ 上做 K_j 次试验，并记录 c_j 次正确回答。
                结束 对于
                通过在线校准估计题目难度：

$$\hat{b}_{p,c} \leftarrow \arg\max_{b} \sum_{j=1}^{m} \Big[c_j \log \sigma(\hat{\theta}_j - b) + (K_j - c_j) \log\big(1 - \sigma(\hat{\theta}_j - b)\big) \Big].$$

                用与原始基准相同的变换归一化 $\hat{b}_{p,c}$，得到 $\hat{z}_{p,c}$。
                将 $(x_{p,c}, \hat{z}_{p,c})$ 加入 $\mathcal{M}$。
                将 $(x_{p,c}, \hat{z}_{p,c})$ 加入 $\mathcal{C}_{\text{valid}}$。
            结束 若
        结束 对于
    结束 对于
    若 $\mathcal{C}_{\text{valid}} \neq \emptyset$ and $\min_{(x,\hat{z}) \in \mathcal{C}_{\text{valid}}} |\hat{z} - z^{\star}| \le \tau$ **则**
        跳出
    结束 若
结束 对于
若 $\mathcal{C}_{\text{valid}} = \emptyset$ **则**
    返回 失败
结束 若
选择最接近的有效子题：

$$(x^{\star}_{\text{item}}, \hat{z}^{\star}) \leftarrow \arg \min_{(x,\hat{z}) \in \mathcal{C}_{\text{valid}}} |\hat{z} - z^{\star}|.$$

返回 $x^{\star}_{\text{item}}$ 作为提议的缺口填补题目，并交由人类专家审核。

E.1 实现细节

对每个基准，我们关注其估计难度分布中三个最显著的间隔，并为每个间隔改写一道题。由于当提示中给出目标难度时，LLM 可能无法可靠区分归一化 $[0,1]$ 难度标尺上的细小数值差异，我们在提示时将难度值重新缩放到 $[0,10]$，而所有报告的指标仍保持在原始归一化标尺上。

对参照列表，我们在目标难度两侧都纳入附近的题目 – 难度对。具体而言，一半参照题选自难度低于目标且最接近目标的题目，另一半选自难度高于目标且最接近目标的题目。这为改写器提供了期望难度水平附近的局部双向上下文。完整的改写提示模板如下。

对难度标注，我们使用与原始难度估计阶段相同的 LLM 集合和相同的生成配置。若迄今找到的最佳有效题目在归一化 $[0, 1]$ 标尺上与目标难度的距离处于容差 $\tau = 0.01$ 之内，搜索提前停止；否则在达到最大轮数后停止。然后我们选择标注难度最接近目标的有效题目。在插入基准之前，每道入选题目都由至少三位人类专家进行人工有效性检查，以核验其正确性。

我们额外实现了一个预算匹配的 best-of-N 均匀父题改写基线。对每个目标间隔 g，令 T_g 表示 BenchFill 在停止前实际运行的轮数。由于 BenchFill 每轮改写 4 个父题、每个父题产生 4 个子题，该间隔的提议预算为 $T_g \times 4 \times 4 = 16T_g$ 个子题。为匹配这一预算，基线均匀抽取 4 道已有基准题作为父题，并让同一个改写 LLM 以父题和目标难度为条件，从每个父题改写出 $4T_g$ 个子题。难度标注之后，它在所有生成候选中选择难度最接近目标的有效子题。因此，基线使用与 BenchFill 相同的总改写预算和相同的最终选择规则，但不使用难度感知的父题检索、附近参照列表或迭代记忆更新。

改写器提示模板

将下面的父题改写为**恰好** 1 道新的基准题变体。目标难度（0--10 标尺，越高越难）：{target_difficulty}。

父题（将此题改写为新变体 —— 不要复制其具体措辞、数字或答案）：
{parent.question}
答案：{parent.reference_answer}
难度（0--10）：{parent.difficulty} | delta {target - parent.difficulty} | generate {harder|easier}

记忆题目（仅用作风格/难度参照，不要复制）：

--- 记忆 1 ---
{memory[0].question}
答案：{memory[0].reference_answer}
难　度　（0--10）：{memory[0].difficulty} | delta {target - memory[0].difficulty} | generate {harder|easier}

--- 记忆 2 ---
{memory[1].question}
答案：{memory[1].reference_answer}
难　度　（0--10）：{memory[1].difficulty} | delta {target - memory[1].difficulty} | generate {harder|easier}

...（每个记忆题目一块）...

只返回一个 markdown 代码块：第一行以 ```json 开始，然后换行，然后是一个**恰好含** 1 个元素的 JSON 数组，再单独一行以 ``` 结束。结束围栏之后不要放任何内容。

在 JSON **语法完整**之前不要停止：每个字符串值都以 " 闭合，每个对象都以 } 闭合，数组以] 结束，然后是结束用的 ``` 行。

该数组必须**恰好含** 1 个元素 —— 一个对象，且恰好包含这些键："id"（字符串），"question"（字符串），"answer"（字符串）。

E.2 补充实验结果

人工验证。 我们用两阶段验证过程确保生成的缺口填补题目可靠。GPT-5.4 首先作为自动有效性评判器，检查每个候选是否格式良好、其参考答案是否正确；未通过该检查的候选被丢弃并重新生成。人类专家随后独立审核最终入选的题目。在 24 个目标间隔中，有一个最初提议的候选因参考答案错误而未通过 GPT-5.4 检查，并被重新生成。全部 24 道最终入选题目都通过了 GPT-5.4 有效性检查，并随后未经修改或替换地通过了人工审核。

改写器能否感知难度？ 一个自然的问题是，我们的改写器是否确实感知难度，而不是盲目地命中目标难度。我们从两个互补角度考察这一问题：改写器在迭代反馈之前是否已经表现出难度敏感性，以及随后的搜索并标注循环是否进一步提高与目标难度的对齐。

首先，为了把改写器自身的难度感知与后来的 IRT 反馈及迭代搜索隔离开，我们只分析每个缺口填补情形的第一轮生成。在此阶段，改写器以指定的目标难度为条件，但尚未收到其生成子题的标注难度反馈。图 7 展示了全部 8 个基准、每个基准 3 个目标间隔上，指定目标难度与有效首轮子题的标注难度。在大多数基准内，更高的指定目标产生更高的平均标注难度，并且分隔良好的目标通常诱导出不同的子题难度分布。这表明，在引入迭代反馈之前，改写器对指定难度标尺已经具有非平凡的敏感性。

其次，我们考察搜索并标注循环是否进一步提高目标对齐。图 8 展示了每个基准中一个有代表性的缺口填补情形。在这些情形中，平均绝对目标偏差总体上从第一轮下降到最后一轮，并且在大多数情形中生成的

表 12: **局部改进检测结果。**每种扩充方法都向原始的 30 题基准增加一道题。增益表示平均准确率的变化。单侧分层随机化检验在每道题内，用 100,000 次置换将 rollout 结果在 SFT 前与 SFT 后条件之间随机重新分配。加粗表示在 $p < 0.05$ 下检测到正增益的变体。

情形	基准变体	增益	单侧 p	是否检出
AIME24 Olmo-3.1-32B-Think	原始	+0.104	0.500100	×
	原始 + BenchFill	**+2.419**	**0.005940**	✓
	原始 + 基线	+0.202	0.458000	×
AIME25 Phi-4	原始	+1.042	0.184100	×
	原始 + BenchFill	**+3.730**	**0.000450**	✓
	原始 + 基线	+0.907	0.214200	×
AIME26 Llama-3.1-8B-Instruct	原始	+0.208	0.418400	×
	原始 + BenchFill	**+3.427**	**0.000010**	✓
	原始 + 基线	+0.101	0.498000	×

子题也更集中于目标附近。这表明，迭代循环利用 IRT 标注与更新后的记忆，进一步细化了改写器最初的难度信号。

检测局部模型改进。 我们进一步考察 BenchFill 是否在缩小难度间隔之外，提高基准检测局部模型改进的能力。我们在 AIME24、AIME25 与 AIME26 中各考虑一个目标间隔，并比较三种基准变体：原始、原始 + BenchFill 与 原始 + 基线。两种扩充方法都向原始基准恰好插入一道题。我们进行轻度 SFT，使模型在目标间隔区域附近得到改进。每道题在 SFT 前后各用 32 次 rollout 评估，并用单侧分层随机化检验（$p < 0.05$）检验增益是否在统计上可检测。

如表 12 所示，原始 + BenchFill 在全部三个情形中都检测到 SFT 后的正增益（3/3），而 原始 与 原始 + 基线 都没有检测到（各为 0/3）。这表明 BenchFill 并非仅仅改进它所优化的指标；通过填补覆盖不足的难度区域，它使基准对否则会被遗漏的局部模型改进更加敏感。

代表性示例。 为定性展示生成的缺口填补题目，我们在表 13 中给出有代表性的改写示例。每个示例同时给出最终入选题目及其在基准中的原始祖先，以及祖先难度、目标难度和入选题目的标注难度。这些示例说明 BenchFill 如何修改已有基准题，以到达先前覆盖不足的难度水平。

表 13: **BenchFill 产生的原始基准祖先与最终入选题目的代表性配对。**所有难度值都归一化到 $[0, 1]$。从祖先题目到入选题目的主要改动被高亮。对入选题目，括号中的值表示目标难度。

基准	原始基准祖先		入选的缺口填补题目	
	题目	难度	题目	难度
AMC23	对多少个整数 n，表达式 $\sqrt{\frac{\log(n^2)-(\log n)^2}{\log n-3}}$ 表示一个实数，其中 log 表示以 10 为底的对数?	0.535	求使得 $\sqrt{\frac{\log(n^2)-(\log n)^2}{\log n-1}}$ 表示实数的整数 n 的个数，其中 log 表示以 10 为底的对数。	0.597 (0.598)
Gaokao2023en	在一个 8×8 的棋盘上放置 6 枚黑车和 k 枚白车，且它们位于不同格子，使得每枚车只攻击相反颜色的车。求 k 的最大可能值。（若两枚车位于同一行或同一列且中间没有其他车，则它们互相攻击。）	0.864	在一个 9×9 的棋盘上放置 7 枚黑车和 k 枚白车，且它们位于不同格子，使得每枚车只攻击相反颜色的车。k 的最大可能值是多少?（若两枚车位于同一行或同一列且中间没有其他车，则它们互相攻击。）	0.886 (0.885)
AIME25	Alex 用两条在圆盘中心相交的垂直直径，将圆盘分成四个象限。他再画 25 条线段穿过圆盘，每条线段随机连接圆周上不同象限中的两点。求这些 27 条线段将圆盘分成的区域数的期望。	0.750	圆上画有一条直径，将其分成两个半圆区域。然后画 8 条弦，每条弦连接一个半圆边界上的随机点与另一个半圆边界上的随机点。假设所有点独立均匀选取，圆的内部被分成的区域数的期望是多少?	0.674 (0.671)

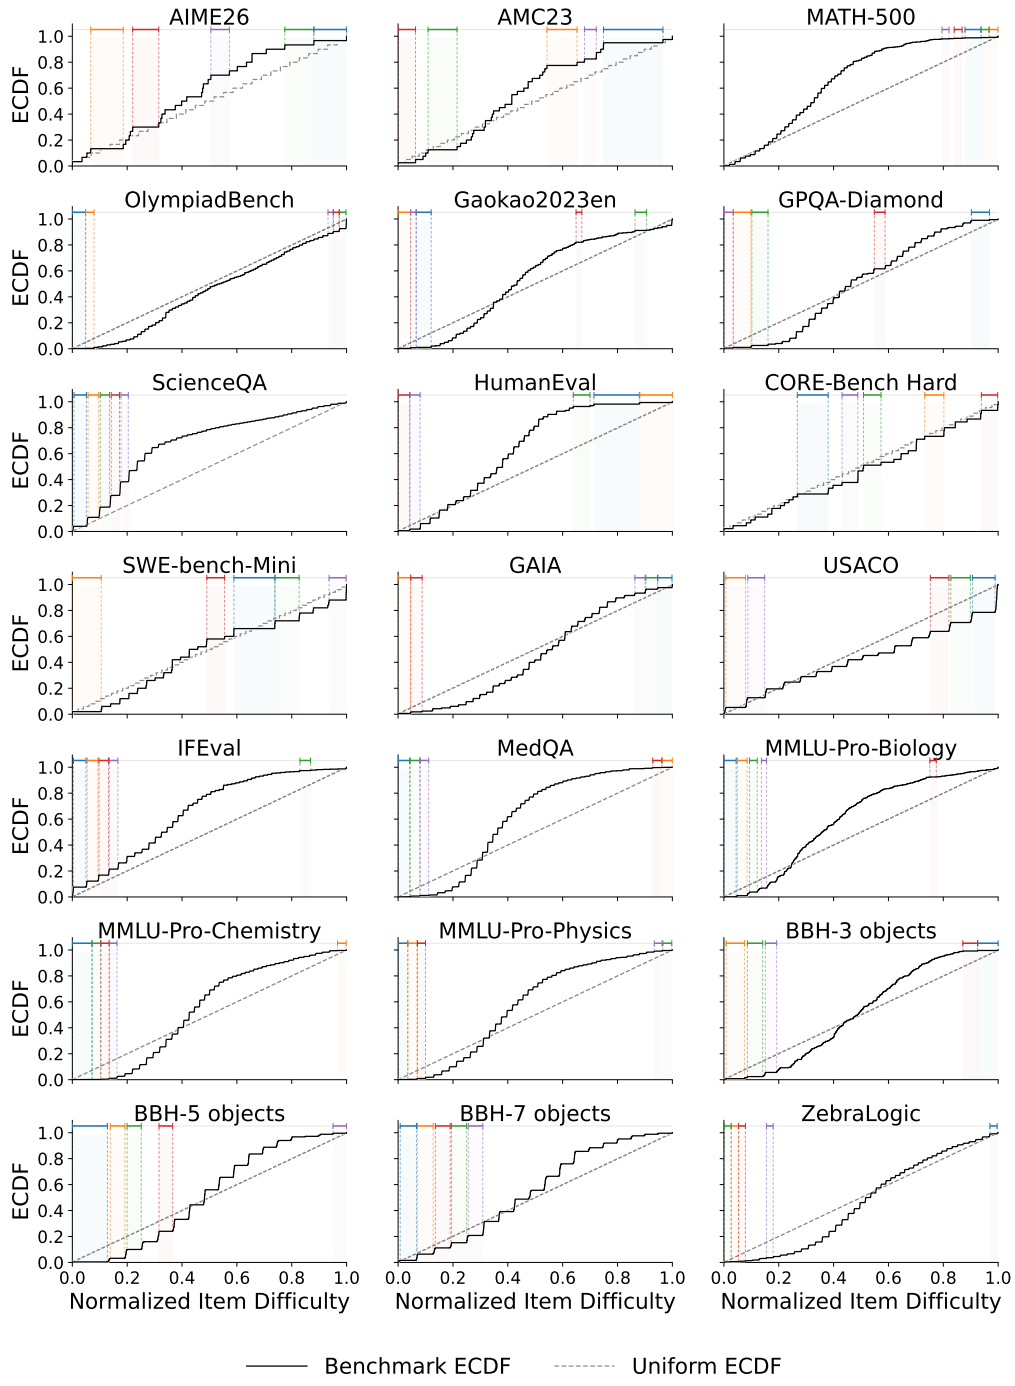

图 6: **补充的基准难度分布。**每个面板展示一个基准归一化题目难度的 ECDF。黑色曲线表示基准 ECDF，灰色虚线表示均匀 ECDF，我们将其用作目标难度分布。偏离均匀 ECDF 表示相对于这一中性目标分布的失配。彩色阴影区间标出排序后题目难度之间五个最大的相邻间隔。

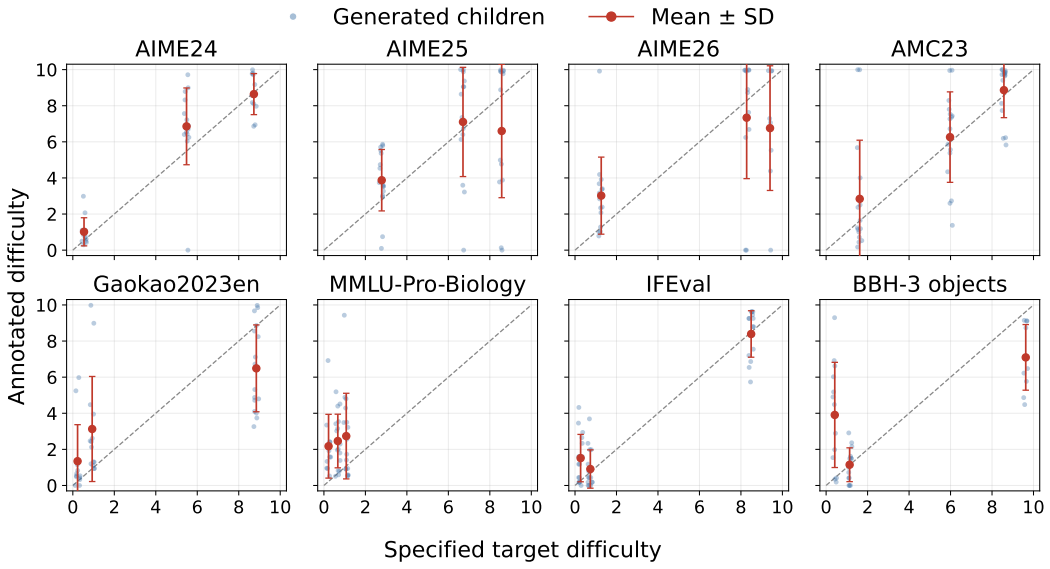

图 7: **指定目标难度与标注难度的首轮对齐。**每个面板对应一个基准。横轴为指定目标难度，纵轴为有效首轮子题的标注难度。蓝点表示单个生成子题，红色标记表示每个目标难度的均值与标准差。虚线对角线表示完全对齐。为便于阅读，两个坐标轴都显示在 0–10 标尺上，对应于 $[0, 1]$ 中的归一化难度乘以 10。在大多数基准内，更高的指定目标在第一轮、即纳入任何迭代反馈之前，就已经产生更高的标注难度。

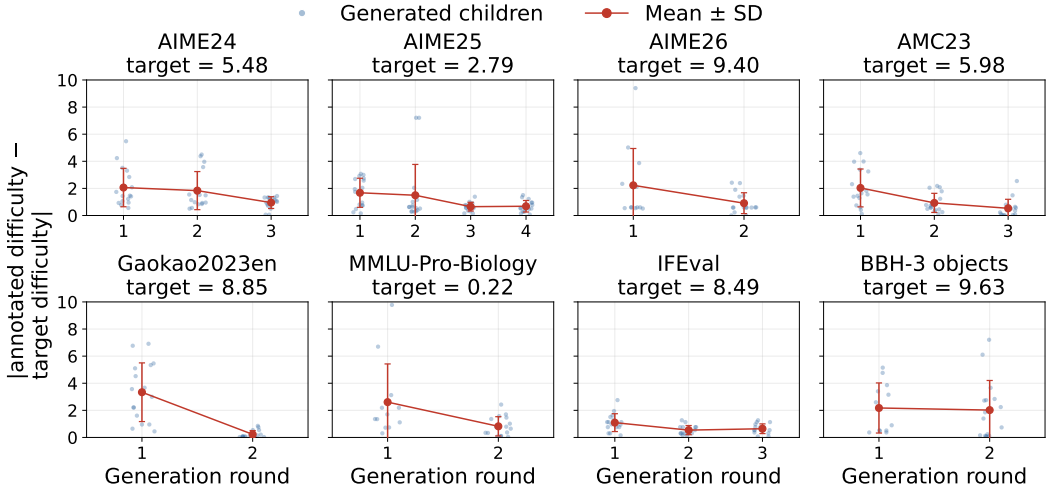

图 8: **BenchFill 搜索过程中的多轮目标对齐。**每个面板展示来自不同基准的一个有代表性的缺口填补情形。横轴为生成轮次，纵轴为生成子题的绝对目标偏差 $|\hat{z} - z^{\star}|$。为便于阅读，目标难度与绝对偏差都乘以 10。蓝点表示单个生成子题，红色标记表示该轮的均值与标准差。在大多数情形中，平均目标偏差随轮次下降，生成的子题更集中于目标附近，表明搜索并标注循环在改写器最初的难度敏感性之外进一步提高了目标对齐。